

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Análise Fatorial (FA), Análise de Correspondência
Múltipla (MCA) e Análise de Múltiplos Fatores

Estatística Multivariada

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

1 INTRODUÇÃO

O objetivo deste trabalho é realizar uma análise multivariada de uma base de dados, usando técnicas como Análise Fatorial (FA), Análise de Correspondência Múltipla (MCA) e Análise de Múltiplos Fatores. Para isso, a base de dados escolhida foi a *Heart Disease* do *UC Irvine Machine Learning Repository*. Essa base de dados é composta de 14 variáveis e 303 observações, sendo que cada observação é um paciente. As variáveis são:

- age: idade;
- sex: sexo;
- chest.pain: tipo de dor peito, podendo ser assintomático, angina típica, angina atípica e sem dor anginal;
- rest.bp: pressão sanguínea em repouso;
- chol: colesterol;
- sugar: glicemia em jejum;
- ecg: resultado do eletrocardiograma, podendo ser normal, anormalidade no segmento ST ou com hipertrofia no ventrículo esquerdo;
- max.rate: frequência cardíaca máxima;
- ang.ex: angina induzida por exercício;
- st.ex_vs_rest: depressão do segmento ST induzida por exercício em comparação com o repouso;
- st.slope: inclinação do segmento ST durante exercício, podendo ser para cima, horizontal ou para baixo;
- fluoroscopy: número de vasos grandes coloridos durante fluoroscopia;
- thalassemia: doença sanguínea que afeta o fluxo sanguíneo, podendo assumir os valores normal, defeito fixo(em alguma parte), defeito reversível;
- hd: doença cardíaca.

2 METODOLOGIA

2.1 Análise Fatorial (FA)

Como a técnica de análise fatorial é utilizada somente para dados numéricos, foram selecionadas apenas as variáveis adequadas. Depois, foi feita a análise fatorial em 2 conjuntos de dados: (i) apenas nos pacientes com doença cardíaca; (ii) apenas nos pacientes saudáveis. O método de análise e o tipo de rotação foram escolhidos de acordo com o menor valor da variância específica de cada combinação.

2.2 Análise de Correspondência Múltipla (MCA)

Ao contrário da análise fatorial, a análise de correspondência múltipla é adequada para dados categóricos. Dessa forma, as variáveis numéricas foram divididas e categorizadas em 3 níveis diferentes, de modo que os níveis sejam proporcionalmente parecidos em quantidade.

2.3 Análise de Múltiplos Fatores (MFA)

A Análise de Múltiplos Fatores (MFA) é empregada para investigar a similaridade entre dois ou mais grupos de variáveis. Neste estudo, os grupos considerados são os indivíduos doentes e não doentes. Para a aplicação adequada da MFA, é necessário que as variáveis de cada grupo sejam da mesma natureza e que o número de observações seja igual em ambos os grupos.

Diante disso, a análise foi conduzida separadamente para os conjuntos de variáveis numéricas e categóricas. Além disso, como os dados estavam desbalanceados entre os grupos, foi utilizada a técnica ROSE (Random Over-Sampling Examples) para gerar observações sintéticas e equilibrar os tamanhos dos grupos.

Para assegurar que o uso da técnica ROSE não compromete a estrutura de similaridade entre as variáveis, a MFA foi também aplicada a uma amostra reduzida do grupo com maior número de observações, bem como aos dados sintéticos de ambos os grupos.

3 RESULTADOS

3.1 Análise Fatorial (FA)

Em ambos os grupos, adotou-se a Análise de Componentes Principais como método de extração. A principal diferença entre as análises esteve no tipo de rotação aplicada: no grupo dos doentes, a rotação *Promax* foi a que melhor minimizou a variância específica das variáveis; já no grupo dos não doentes, a rotação mais adequada foi a *Varimax*.

Analizando os resultados, para o grupo de pacientes com doença cardíaca, a análise extraiu dois fatores principais com autovalores superiores a 1.0, que juntos explicam 47,71% da variância total dos dados (Tabela 1).

Analizando as cargas fatoriais (Tabela 2), o fator 1 é fortemente influenciado negativamente pelas variáveis age (idade, carga = -0,76) e fluoroscopy (fluoroscopia, carga = -0,89). Isso indica que, neste grupo, a idade avançada e um maior número de vasos principais visualizados por fluoroscopia são as características mais proeminentes que se agrupam.

Em contrapartida, o fator 2 é quase exclusivamente definido pela variável max.rate (frequência cardíaca máxima, carga = 0,99), que se mostra independente das variáveis do primeiro fator.

Tabela 1: FA - autovalores e variância explicada nos pacientes com doença

Componente	Autovalor	% da Variância	% Acumulada da Variância
Fator 1	1.6689	27.815	27.82
Fator 2	1.1936	19.893	47.71
Fator 3	0.9493	15.822	63.53
Fator 4	0.8575	14.291	77.82
Fator 5	0.8021	13.368	91.19
Fator 6	0.5287	8.811	100.00

Para o grupo sem doença cardíaca, a análise também identificou dois fatores principais que, somados, explicam 49,13% da variância total (Tabela 3). A estrutura desses fatores, no entanto, é notavelmente diferente da encontrada no grupo doente (Tabela 4).

A variável mais dominante no fator 1 representa uma clara oposição entre age

Tabela 2: FA - cargas fatoriais nos pacientes com doença

Variável	Carga Fatorial					Comun.	Var. Espec.
	Fator 1	Fator 2	Fator 3	Fator 4	Fator 5		
age	-0.76	-0.14	-0.28	-0.05	-0.19	0.71	0.29
rest.bp	0.05	0.08	-0.97	0.03	0.12	0.97	0.03
chol	-0.01	-0.02	-0.03	0.99	-0.03	0.99	0.01
max.rate	-0.03	0.99	-0.09	-0.02	-0.07	0.99	0.01
st.ex_vs_rest	-0.04	-0.06	-0.12	-0.02	0.96	0.94	0.06
fluoroscapy	-0.89	0.12	0.23	0.05	0.18	0.90	0.10
Variancia	1.67	1.19	0.95	0.86	0.80	5.49	NA
% Variancia	27.82	19.89	15.82	14.29	13.37	91.19	NA

(idade, carga = -0,79) e max.rate (frequência cardíaca máxima, carga = 0,92). Já o segundo fator é predominantemente definido pela variável rest.bp (pressão arterial de repouso, carga = -0,98)

Tabela 3: FA - autovalores e variância explicada nos pacientes sem doença

Componente	Autovalor	% da Variância	% Acumulada da Variância
Fator 1	1.8363	30.605	30.61
Fator 2	1.1114	18.523	49.13
Fator 3	1.0596	17.660	66.79
Fator 4	0.8615	14.358	81.15
Fator 5	0.7926	13.209	94.36
Fator 6	0.3386	5.644	100.00

3.2 Análise de Correspondência Múltipla (MCA)

A Análise de Correspondência Múltipla (MCA) foi empregada para investigar as associações subjacentes em um conjunto de variáveis categóricas, buscando visualizar perfis de pacientes e a estrutura de inter-relações entre suas características. A análise se mostrou eficaz, com as duas primeiras dimensões explicando um total de 46,60% da variância dos dados (Tabela 5).

A primeira dimensão, que é a mais importante, responde por uma parcela substancial de 38,99% da variância total, estabelecendo o principal eixo de diferenciação no conjunto de dados. A interpretação deste eixo horizontal revela um gradiente de risco e severidade de doença cardíaca (Figura 1). De um lado, agrupam-se as

Tabela 4: FA - cargas fatoriais nos pacientes sem doença

Variável	Carga Fatorial					Comun.	Var. Espec.
	Fator 1	Fator 2	Fator 3	Fator 4	Fator 5		
age	-0.79	-0.32	-0.25	0.20	-0.03	0.83	0.17
rest.bp	-0.04	-0.98	-0.03	0.00	-0.10	0.97	0.03
chol	-0.04	-0.04	-0.99	0.04	-0.03	0.98	0.02
max.rate	0.92	-0.13	-0.10	0.01	0.11	0.89	0.11
st.ex_vs_rest	-0.11	-0.10	-0.03	-0.01	-0.99	1.00	0.00
fluoroscopy	-0.10	0.00	-0.04	0.99	0.01	0.99	0.01
Variancia	1.84	1.11	1.06	0.86	0.79	5.66	NA
% Variancia	30.61	18.52	17.66	14.36	13.21	94.36	NA

categorias que indicam um perfil de alto risco, como a presença de doença cardíaca (hd:Disease), angina induzida por exercício (ang.ex:Sim), resultados anormais de talassemia (thalassemia:Reversible Defect, Fixed Defect) e indicadores de ECG preocupantes, como a depressão do segmento ST (st.slope:Down, Flat). Em oposição, o polo esquerdo do eixo caracteriza um perfil de saúde, sendo definido pela ausência de doença cardíaca (hd:No Disease), ausência de angina de esforço (ang.ex:Não), talassemia normal e uma frequência cardíaca máxima elevada, sinal de boa condição física.

A segunda dimensão, responsável por 7,61% da variância, acrescenta uma camada de detalhe ao diferenciar os perfis demográficos e clínicos dos indivíduos. A parte superior do eixo vertical tende a agrupar características de um perfil mais velho e feminino (age:[59,77], sex:Female), que pode apresentar comorbidades como hiperglicemia (sugar:High). Em contraste, a parte inferior do gráfico está associada a um perfil mais jovem e masculino (age:[29,51], sex:Male), com leituras clínicas mais próximas da normalidade, como um ECG normal.

Em resumo, a MCA conseguiu estruturar os dados de forma significativa. A análise não só confirmou associações clinicamente esperadas, como também destacou um eixo primário de saúde cardiovascular que separa eficazmente os perfis de baixo e alto risco. Adicionalmente, revelou uma dimensão secundária que contrasta diferentes perfis de pacientes, oferecendo uma visão abrangente das relações no conjunto de dados.

Tabela 5: MCA - autovalores e variância explicada por Componente

Componente	Autovalor	% da Variância	% Acumulada da Variância
Comp 1	0.07	38.99	38.99
Comp 2	0.01	7.61	46.60
Comp 3	0.01	5.92	52.51
Comp 4	0.01	5.52	58.03
Comp 5	0.01	4.71	62.74
Comp 6	0.01	4.21	66.96
Comp 7	0.01	3.57	70.52
Comp 8	0.01	3.31	73.83
Comp 9	0.01	2.86	76.69
Comp 10	0.01	2.76	79.44




Figura 1: MCA - associação entre cada variável

3.3 Análise de Múltiplos Fatores (MFA)

Os resultados de similaridade da MFA foram parecidos nos dados amostrados e nos dados simulados, tanto para as variáveis numéricas (Tabelas 6 e 7) quanto para as categóricas (Tabelas 9 e 10). Dessa forma, foi possível utilizar os dados sintéticos apenas no grupo menor e garantir a qualidade do resultado final (Tabelas 8 e 11).

Como esperado, não há similaridade forte entre os grupos de variáveis (doentes e não doentes).

Tabela 6: MFA - Inércias parciais dos dados numéricos amostrados

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.5843	0.4191	0.4194	0.4974
Não Doentes	0.4784	0.5635	0.3914	0.1994

Tabela 7: MFA - Inércias parciais dos dados numéricos sintéticos

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.5577	0.4491	0.1451	0.6217
Não Doentes	0.5312	0.4998	0.6911	0.0968

Tabela 8: MFA - Inércias parciais dos dados numéricos (resultado)

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.6386	0.4412	0.4732	0.3192
Não Doentes	0.4200	0.5950	0.2730	0.3114

Tabela 9: MFA - Inércias parciais dos dados categóricos amostrados

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.6818	0.2504	0.2019	0.5094
Não Doentes	0.5661	0.8161	0.7966	0.4098

Tabela 10: MFA - Inércias parciais dos dados categóricos sintéticos

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.7431	0.1346	0.1607	0.1364
Não Doentes	0.4498	0.9174	0.7822	0.7494

Tabela 11: MFA - Inércias parciais dos dados categóricos (resultado)

Variável	Comp. 1	Comp. 2	Comp. 3	Comp. 4
Doentes	0.6245	0.3944	0.2039	0.1499
Não Doentes	0.4900	0.6912	0.7728	0.7469

4 CONCLUSÃO

As estruturas dos dados e as relações entre as variáveis são notavelmente distintas quando se comparam pacientes com e sem doença cardíaca.

A Análise Fatorial (FA) demonstrou que os fatores mais importantes e a forma como as variáveis numéricas se agrupam diferem entre os dois grupos. Similarmente, a Análise de Correspondência Múltipla (MCA) revelou um eixo principal que separa claramente os perfis de saúde e doença com base nas variáveis categóricas, indicando padrões de associação distintos para cada grupo.

Finalmente, a Análise de Múltiplos Fatores (MFA) confirmou a falta de uma forte similaridade entre os grupos de doentes e não doentes, tanto para as variáveis numéricas quanto para as categóricas. Em conjunto, as três técnicas estatísticas convergem para a mesma conclusão.