

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Análise de Variância Multivariada(MANOVA)

Estatística Multivariada

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

# 1 INTRODUÇÃO

O objetivo deste trabalho é realizar uma análise multivariada de uma base de dados, usando técnicas como Teste de Normalidade Multivariado, Intervalo de Confiança Multivariado, Teste de Hipótese para Comparação de Vetores Médios e Análise de Variância Multivariada (MANOVA).

Para isso, a base de dados escolhida foi a *Heart Disease* do *UC Irvine Machine Learning Repository*. Essa base de dados é composta de 14 variáveis e 303 observações, sendo que cada observação é um paciente. As variáveis são:

- age: idade;
- sex: sexo;
- chest.pain: tipo de dor peito, podendo ser assintomático, angina típica, angina atípica e sem dor anginal;
- rest.bp: pressão sanguínea em repouso;
- chol: colesterol;
- sugar: glicemia em jejum;
- ecg: resultado do eletrocardiograma, podendo ser normal, anormalidade no segmento ST ou com hipertrofia no ventrículo esquerdo;
- max.rate: frequência cardíaca máxima;
- ang.ex: angina induzida por exercício;
- st.ex\_vs\_rest: depressão do segmento ST induzida por exercício em comparação com o repouso;
- st.slope: inclinação do segmento ST durante exercício, podendo ser para cima, horizontal ou para baixo;
- fluoroscopy: número de vasos grandes coloridos durante fluoroscopia;
- thalassemia: doença sanguínea que afeta o fluxo sanguíneo, podendo assumir os valores normal, defeito fixo(em alguma parte), defeito reversível;
- hd: doença cardíaca.

## 2 METODOLOGIA

### 2.1 Análise de Dados e Teste de Normalidade

Inicialmente, o conjunto de dados foi carregado e pré-processado, selecionando-se as variáveis numéricas relevantes para a análise. Os dados foram então segmentados em dois grupos distintos com base na variável categórica `hd`, que indica a presença (*Disease*) ou ausência (*No Disease*) da doença.

A premissa de normalidade multivariada, fundamental para os testes paramétricos subsequentes, foi avaliada para cada grupo de forma independente. Para isso, foi empregado o teste de Royston. Adicionalmente, a normalidade univariada de cada variável dentro de cada grupo foi verificada pelo teste de Anderson-Darling (AD). A detecção de outliers multivariados foi realizada por meio do método da distância de Mahalanobis ajustada.

### 2.2 Construção de Intervalos de Confiança Multivariados

Para estimar os vetores de médias populacionais dos grupos com e sem a doença, foram construídos intervalos de confiança simultâneos de 95% para a média de cada variável. Duas abordagens foram utilizadas e comparadas:

1. **Método  $T^2$  de Hotelling:** Foram calculados intervalos de confiança simultâneos baseados na estatística  $T^2$  de Hotelling, que utiliza um valor crítico derivado da distribuição F para garantir o nível de confiança global para todas as variáveis.
2. **Método de Bonferroni:** Foram calculados intervalos de confiança simultâneos utilizando a correção de Bonferroni, que ajusta o nível de significância de cada intervalo individual com base em um valor crítico da distribuição t de Student.

Os resultados de ambas as metodologias foram agrupados e visualizados graficamente para permitir a comparação direta dos intervalos entre os métodos e entre os grupos de pacientes.

## 2.3 Teste de Hipóteses para Comparação de Médias

Para testar formalmente a hipótese nula de igualdade entre os vetores de médias dos grupos, foi realizado o teste  $T^2$  de Hotelling para duas amostras independentes. A estatística  $T^2$  calculada foi comparada com o valor crítico da distribuição F correspondente, com  $\alpha = 0,05$ , para determinar a significância estatística da diferença entre os vetores de médias.

## 2.4 Análise de Variância Multivariada (MANOVA)

De forma complementar, foi conduzida uma Análise de Variância Multivariada (MANOVA) de uma via para avaliar o efeito global da variável independente **hd** (status da doença) sobre o conjunto de variáveis dependentes numéricas. Após a verificação do resultado do teste multivariado global, foram examinadas as Análises de Variância (ANOVAs) univariadas para cada variável dependente. Como análise post-hoc, o teste de Tukey foi aplicado para realizar comparações par a par entre os grupos em cada variável que se mostrou significativa, a fim de detalhar as diferenças específicas.

# 3 RESULTADOS

## 3.1 Testes de Normalidade

A premissa de normalidade multivariada foi avaliada pelo teste de Royston (Figura 1). Os resultados indicaram que ambos os grupos, *Disease* e *No Disease*, violaram a suposição de normalidade multivariada ( $p < 0.001$  para ambos).

Tabela 1: Resultados do Teste de Normalidade Multivariada de Royston.

| Grupo      | Valor-p   | Normalidade |
|------------|-----------|-------------|
| Disease    | $< 0.001$ | X           |
| No Disease | $< 0.001$ | X           |

Adicionalmente, os testes de normalidade univariada de Anderson-Darling foram conduzidos para cada variável dentro de cada grupo. Os resultados estão detalhados na

Tabela 2. Múltiplas variáveis, como `age` e `rest.bp` no grupo *Disease*, e `rest.bp` e `chol` no grupo *No Disease*, não seguiram uma distribuição normal.

Tabela 2: Resultados do Teste de Normalidade Univariada de Anderson-Darling.

| Grupo      | Variável      | Valor-p | Normalidade |
|------------|---------------|---------|-------------|
| Disease    | age           | < 0.001 | X           |
|            | rest.bp       | < 0.001 | X           |
|            | chol          | 0.92    | ✓           |
|            | max.rate      | 0.183   | ✓           |
|            | st.ex_vs_rest | < 0.001 | X           |
| No Disease | age           | 0.061   | ✓           |
|            | rest.bp       | 0.01    | X           |
|            | chol          | < 0.001 | X           |
|            | max.rate      | < 0.001 | X           |
|            | st.ex_vs_rest | < 0.001 | X           |

### 3.2 Intervalos de Confiança e Análise Gráfica

Foram construídos intervalos de confiança simultâneos de 95% para a média de cada variável em ambos os grupos, utilizando os métodos de Bonferroni e  $T^2$  de Hotelling (Tabela 3). A Figura 1 ilustra visualmente estes intervalos, permitindo a comparação entre os métodos e os grupos. O gráfico demonstra as diferenças nas médias estimadas, com o grupo Doentes apresentando, por exemplo, maior idade (`age`) e menor frequência cardíaca máxima (`max.rate`) em comparação ao grupo Não Doentes.

Tabela 3: Intervalos de Confiança de 95% Agrupados por Variável.

| Variável      | Grupo      | Método     | Limite Inferior | Limite Superior |
|---------------|------------|------------|-----------------|-----------------|
| age           | Não Doente | Bonferroni | 50.60           | 54.57           |
|               |            | Hotelling  | 49.87           | 55.30           |
|               | Doente     | Bonferroni | 54.82           | 58.43           |
|               |            | Hotelling  | 54.15           | 59.10           |
| rest.bp       | Não Doente | Bonferroni | 125.87          | 132.63          |
|               |            | Hotelling  | 124.63          | 133.87          |
|               | Doente     | Bonferroni | 130.31          | 138.83          |
|               |            | Hotelling  | 128.72          | 140.42          |
| chol          | Não Doente | Bonferroni | 231.49          | 253.79          |
|               |            | Hotelling  | 227.39          | 257.89          |
|               | Doente     | Bonferroni | 240.24          | 262.71          |
|               |            | Hotelling  | 236.06          | 266.89          |
| max.rate      | Não Doente | Bonferroni | 154.37          | 162.38          |
|               |            | Hotelling  | 152.90          | 163.86          |
|               | Doente     | Bonferroni | 134.13          | 144.39          |
|               |            | Hotelling  | 132.22          | 146.30          |
| st.ex_vs_rest | Não Doente | Bonferroni | 0.42            | 0.75            |
|               |            | Hotelling  | 0.36            | 0.81            |
|               | Doente     | Bonferroni | 1.28            | 1.87            |
|               |            | Hotelling  | 1.17            | 1.98            |
| fluoroscopy   | Não Doente | Bonferroni | 0.14            | 0.40            |
|               |            | Hotelling  | 0.09            | 0.45            |
|               | Doente     | Bonferroni | 0.90            | 1.36            |
|               |            | Hotelling  | 0.81            | 1.45            |




Figura 1: Intervalos de confiança de 95% para cada variável, separados por status da doença (Não Doentes vs. Doentes) e método de cálculo (Bonferroni vs. Hotelling).

### 3.3 Análises Multivariadas de Comparação de Grupos

O teste  $T^2$  de Hotelling para duas amostras revelou uma diferença estatisticamente significativa entre os vetores de médias dos grupos *Disease* e *No Disease*. O valor da estatística de teste foi  $T^2 = 172.623$ , superando o valor crítico tabelado de 12.991, com um valor-p de 0.

De forma consistente, a Análise de Variância Multivariada (MANOVA) também indicou um efeito estatisticamente significativo do status da doença sobre o conjunto de variáveis dependentes ( $p < 0.001$ ).

### 3.4 Análises Univariadas e Comparações Post-Hoc

Após a confirmação da significância multivariada, foram realizadas análises de variância (ANOVA) univariadas para cada variável dependente. Conforme detalhado na Tabela

4, todas as variáveis, com exceção de `chol` ( $p = 0.139$ ), apresentaram diferenças estatisticamente significativas entre os grupos.

Tabela 4: Resultados das Análises de Variância (ANOVA) Univariadas.

| Variável      | F      | Valor-p   | Significativo? |
|---------------|--------|-----------|----------------|
| age           | 15.77  | $< 0.001$ | ✓              |
| rest.bp       | 7.0066 | 0.0085    | ✓              |
| chol          | 2.1991 | 0.1391    | X              |
| max.rate      | 63.419 | $< 0.001$ | ✓              |
| st.ex_vs_rest | 66.167 | $< 0.001$ | ✓              |
| fluoroscopy   | 80.801 | $< 0.001$ | ✓              |

Os testes post-hoc de Tukey confirmaram esses achados: todas as variáveis apresentaram diferenças significativas entre os grupos, com a única exceção da variável `chol`, cujo intervalo de confiança  $[-20.56, 2.89]$  contém o zero, corroborado por um valor-p não significativo ( $p = 0.139$ ). (Tabela 5).

Tabela 5: Resultados do Teste Post-Hoc de Tukey para Comparação entre Grupos.

| Variável      | No Disease - Disease | IC 95%           | Valor-p   | Significativo? |
|---------------|----------------------|------------------|-----------|----------------|
| age           | -4.04                | $[-6.04, -2.04]$ | $< 0.001$ | ✓              |
| rest.bp       | -5.32                | $[-9.27, -1.36]$ | 0.009     | ✓              |
| chol          | -8.83                | $[-20.56, 2.89]$ | 0.139     | X              |
| max.rate      | 19.12                | $[14.39, 23.84]$ | $< 0.001$ | ✓              |
| st.ex_vs_rest | -0.99                | $[-1.23, -0.75]$ | $< 0.001$ | ✓              |
| fluoroscopy   | -0.86                | $[-1.05, -0.67]$ | $< 0.001$ | ✓              |

## 4 CONCLUSAO

A análise multivariada demonstrou de forma conclusiva que existe uma diferença estatisticamente significativa no perfil das variáveis fisiológicas entre os pacientes com e sem doença cardíaca. Tanto o teste  $T^2$  de Hotelling quanto a MANOVA confirmaram que os vetores de médias dos dois grupos não são iguais ( $p < 0.001$ ).

Especificamente, as análises univariadas revelaram que cinco das seis variáveis



analisadas — idade, pressão arterial de repouso, frequência cardíaca máxima, depressão do segmento ST e fluoroscopia — contribuíram significativamente para essa diferença. Pacientes diagnosticados com a doença tenderam a ser mais velhos e a apresentar maior pressão arterial, maior depressão do segmento ST e maior número de vasos visualizados, além de uma frequência cardíaca máxima inferior. Notavelmente, os níveis de colesterol (`chol`) não apresentaram diferença estatística entre os dois grupos ( $p = 0.139$ ).

Em suma, os resultados reforçam a existência de um perfil clínico distinto para indivíduos com doença cardíaca e destacam a importância de avaliar múltiplas variáveis em conjunto para a caracterização da condição. Entretanto, é importante ressaltar que a premissa de normalidade multivariada não foi atendida por nenhum dos grupos