

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Classificação Supervisionada

Mineração de Dados

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

1 INTRODUÇÃO

O objetivo deste trabalho é criar vários modelos de classificação e compará-los em performance. Para isso, a base de dados escolhida foi a *Heart Disease* do *UC Irvine Machine Learning Repository*. Essa base de dados é composta de 14 variáveis e 303 observações, sendo que cada observação é um paciente e há 139 pacientes com doença cardíaca e 164 sem. As variáveis são:

- age: idade;
- sex: sexo;
- chest.pain: tipo de dor peito, podendo ser assintomático, angina típica, angina atípica e sem dor anginal;
- rest.bp: pressão sanguínea em repouso;
- chol: colesterol;
- sugar: glicemia em jejum;
- ecg: resultado do eletrocardiograma, podendo ser normal, anormalidade no segmento ST ou com hipertrofia no ventrículo esquerdo;
- max.rate: frequência cardíaca máxima;
- ang.ex: angina induzida por exercício;
- st.ex_vs_rest: depressão do segmento ST induzida por exercício em comparação com o repouso;
- st.slope: inclinação do segmento ST durante exercício, podendo ser para cima, horizontal ou para baixo;
- fluoroscopy: número de vasos grandes coloridos durante fluoroscopia;
- thalassemia: doença sanguínea que afeta o fluxo sanguíneo, podendo assumir os valores normal, defeito fixo(em alguma parte), defeito reversível;
- hd: doença cardíaca.

2 METODOLOGIA

Com o objetivo de criar um modelo para classificar se um paciente possui ou não uma doença cardíaca com base em algumas características, foram testados alguns modelos

estudados em sala de aula, como *K-Nearest Neighbors*, *Naive Bayes*, *Logistic Regression*, *Linear Discriminant Analysis*, *Decision Trees*, *Random Forests*, *Gradient Boosting Machines* e *Neural Networks*.

Para isso, primeiro foi feita uma análise exploratória para entender mais sobre a distribuição dos dados, depois o próprio modelo em si. Desse modo, os dados foram separados em duas partes, uma para treinamento do modelo (70%) e outra para testar e calcular as métricas de desempenho (30%). Além disso, alguns modelos possuem hiperparâmetros que precisam ser otimizados. Isso foi feito usando a técnica de validação cruzada com 10 partes.

No processo de otimizar os hiperparâmetros, a acurácia foi o principal indicador utilizado, porém no momento de avaliar os resultados nos dados de teste, outras métricas foram utilizadas, tais como F-score, índice Kappa, Precisão, Recall, área sob a curva ROC, Sensibilidade e Especificidade.

Além de métricas de desempenho, também foi avaliada a importância de cada variável no poder preditivo do modelo para os que se saíram melhores.

3 RESULTADOS

3.1 Estatística Descritiva

Analisando as variáveis nominais (figura 1), ao separá-las pela presença de doença cardíaca, podemos já tirar algumas conclusões, como prevalência no sexo masculino, a maioria daqueles que não possuem sintomas de dor no peito possui a doença, aqueles com anormalidades no segmento ST do eletrocardiograma tem maior prevalência da doença, a presença de algum tipo de talassemia é comum entre os que possuem a doença e, por fim, a doença é mais frequente entre os pacientes com angina durante o exercício.

Além disso, ao fazer o boxplot de cada variável numérica (figura 2), separadas pela presença de doença, vemos que pessoas mais velhas tendem a ter mais as doenças, o número de vasos que colorem durante a fluoroscopia parece influenciar muito, pessoas cujo coração suporta batimentos mais elevados possuem menos doença e, por último, a depressão do segmento ST no exercício é mais elevada entre os que possuem a doença.




Figura 1: Gráficos das variáveis nominais em relação à presença ou não de doença cardíaca




Figura 2: Boxplot das variáveis numéricas, separadas pela presença ou não de doença cardíaca




Figura 3: Gráfico de correlação entre as variáveis numéricas

Por último, o gráfico de correlação entre as variáveis (figura 3) mostra que é baixa a correlação entre as variáveis, o que indica que haverá pouco problema de multicolinearidade.

3.2 Métricas dos Modelos

3.2.1 Validação Cruzada

Na validação cruzada realizada nos dados de treinamento, os resultados não diferiram muito, porém os três melhores modelos são: *neural networks*, *linear discriminant analysis* e *random forests*.




Figura 4: Métricas da validação cruzada

3.2.2 Dados de Teste

Já nos dados de teste, os resultados (tabela 1 e figura 4) indicam que a regressão logística foi o modelo que se saiu melhor na maioria das métricas, com uma acurácia de 83%.

Tabela 1: Métricas nos dados de teste

métrica	naive	knn	logit	lda	tree	forest	gbm	nnet
accuracy	0.8026	0.8026	0.8289	0.8026	0.7500	0.8158	0.8289	0.7895
sensitivity	0.8780	0.8049	0.8293	0.8537	0.8537	0.8537	0.9024	0.8293

métrica	naive	knn	logit	lda	tree	forest	gbm	nnet
specificity	0.7143	0.8000	0.8286	0.7429	0.6286	0.7714	0.7429	0.7429
precision	0.7826	0.8250	0.8500	0.7955	0.7292	0.8140	0.8043	0.7907
recall	0.8780	0.8049	0.8293	0.8537	0.8537	0.8537	0.9024	0.8293
f_meas	0.8276	0.8148	0.8395	0.8235	0.7865	0.8333	0.8506	0.8095
kap	0.5986	0.6036	0.6565	0.6003	0.4894	0.6277	0.6521	0.5745
roc_auc	0.8934	0.8606	0.8669	0.8732	0.7446	0.8864	0.8913	0.8655




Figura 5: Métricas nos dados de teste

3.3 Importância das Variáveis

É possível também calcular a importância de cada variável para prever a doença cardíaca. Porém essa importância varia de modelo para modelo. Na figura 6A temos a importância de cada variável no modelo GBM e na figura 6B na regressão logística.




Figura 6: Importância das Variáveis

3.4 Inferência

Como a regressão logística é um modelo linear generalizado é possível fazer inferência e tirar conclusões dos coeficientes (tabela 2). Para isso, eu ajustei o modelo no conjunto de dados completo. Na tabela, selecionei apenas as variáveis cujo valor-p é menor que 0,05 e confirmamos a análise feita inicialmente. Podemos concluir que ser do sexo masculino aumenta em quase 5x as chances de ter doença cardíaca em comparação ao sexo feminino, para cada vaso que se colore na fluoroscopia, aumenta em 3,65x a chance de ter uma doença, ter uma talassemia com defeito reversível aumenta em 3,7x em comparação com não ter e, por fim, pacientes com alguma dor no peito tem menos chance de ter uma doença em comparação com aqueles assintomáticos. Isso pode ser explicado pelo fato de que a maior parte dos pacientes são assintomáticos e a grande maioria dos doentes que possuem doença cardíaca também são assintomáticos.

Tabela 2: Coeficientes da regressão logística

term	estimate	exp(estimate)
sexMale	1.5723	4.8175
chest.painNon-anginal Pain	-1.9154	0.1473
chest.painTypical Angina	-2.1555	0.1158
rest.bp	0.0242	1.0245
fluoroscopia	1.2958	3.6539
thalassemiaReversible Defect	1.3085	3.7008

4 CONCLUSÃO

O modelo mais adequado para se utilizar para prever se a pessoa terá ou não doença cardíaca é a regressão logística, por ser mais simples e igualmente ou até mais precisa que um modelo mais complexo, com uma acurácia de quase 83% e área sob a curva roc de 0,86.