

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Classificação não Supervisionada, Regras de
Associação, Mineração de Textos e Análise de Sentimentos

Mineração de Dados

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

Sumário

1	INTRODUÇÃO	2
2	METODOLOGIA	3
2.1	Pré-processamento dos Dados	3
2.2	Análise de Agrupamento	3
2.2.1	Agrupamento Hierárquico	3
2.2.2	Definição do Número Ótimo de Clusters e K-means	3
2.3	Regras de Associação	4
2.4	Mineração de Textos e Análise de Sentimentos	4
3	RESULTADOS	5
3.1	Análise de Clusters	5
3.2	Regras de Associação	6
3.2.1	Perfil do Cluster 1	6
3.2.2	Perfil do Cluster 2	7
3.3	Análise de Sentimentos	7
4	CONCLUSÃO	9

1 INTRODUÇÃO

O objetivo deste trabalho é realizar uma análise de uma base de dados, usando técnicas como Classificação não Supervisionada e Regras de Associação. Para isso, a base de dados escolhida foi a *Heart Disease* do *UC Irvine Machine Learning Repository*. Essa base de dados é composta de 14 variáveis e 303 observações, sendo que cada observação é um paciente. As variáveis são:

- age: idade;
- sex: sexo;
- chest.pain: tipo de dor peito, podendo ser assintomático, angina típica, angina atípica e sem dor anginal;
- rest.bp: pressão sanguínea em repouso;
- chol: colesterol;
- sugar: glicemia em jejum;
- ecg: resultado do eletrocardiograma, podendo ser normal, anormalidade no segmento ST ou com hipertrofia no ventrículo esquerdo;
- max.rate: frequência cardíaca máxima;
- ang.ex: angina induzida por exercício;
- st.ex_vs_rest: depressão do segmento ST induzida por exercício em comparação com o repouso;
- st.slope: inclinação do segmento ST durante exercício, podendo ser para cima, horizontal ou para baixo;
- fluoroscopy: número de vasos grandes coloridos durante fluoroscopia;
- thalassemia: doença sanguínea que afeta o fluxo sanguíneo, podendo assumir os valores normal, defeito fixo(em alguma parte), defeito reversível;
- hd: doença cardíaca.

Além disso, a segunda parte do trabalho é realizar uma mineração de textos e análise de sentimentos. Para isso, foram escolhidos alguns comentários do *Ifood*, da hamburgueria *Street Burger*.

2 METODOLOGIA

Neste estudo, foi empregada uma sequência de técnicas de aprendizado de máquina não supervisionado e mineração de dados para identificar e caracterizar perfis distintos em um conjunto de dados de pacientes. A metodologia foi dividida em três etapas principais: pré-processamento dos dados, análise de agrupamento (cluster) e mineração de regras de associação.

2.1 Pré-processamento dos Dados

O conjunto de dados inicial foi preparado para a análise de agrupamento. As variáveis numéricas foram padronizadas, resultando em variáveis com média zero e desvio padrão um. As variáveis categóricas (fatores) foram transformadas em um formato numérico através da criação de variáveis *dummy* e foi retirada a variável resposta *hd* antes de aplicar as técnicas. Ao final, as variáveis numéricas padronizadas e as variáveis *dummy* foram combinadas em um único banco de dados para a etapa de clusterização.

2.2 Análise de Agrupamento

Para identificar grupos de indivíduos com características similares, foram aplicadas técnicas de agrupamento hierárquico e não hierárquico.

2.2.1 Agrupamento Hierárquico

Inicialmente, foi calculada uma matriz de dissimilaridade entre as observações utilizando a distância de Canberra. Subsequentemente, o algoritmo de agrupamento hierárquico foi aplicado utilizando o método de Ward (Ward.D), que visa minimizar a variância total dentro dos clusters. O resultado foi visualizado por meio de um dendrograma para inspecionar a estrutura hierárquica dos dados.

2.2.2 Definição do Número Ótimo de Clusters e K-means

O número ideal de clusters foi determinado pelo método da Silhueta Média. Foram testadas configurações de 2 a 10 clusters, e o número que apresentou a maior largura média

de silhueta foi considerado o ideal. Com base neste número, foi aplicado o algoritmo não hierárquico K-means para particionar os dados no número ótimo de grupos.

2.3 Regras de Associação

Após a atribuição de cada paciente a um cluster, buscou-se caracterizar cada grupo através de regras de associação. Para esta etapa, as variáveis numéricas do conjunto de dados original foram discretizadas em três níveis (“Baixo”, “Médio”, “Alto”) com base em tercis. A variável de identificação do cluster foi então adicionada a este novo conjunto de dados.

O algoritmo Apriori foi aplicado para extrair regras de associação. Foram estabelecidos limiares mínimos de 0.2 para o suporte e 0.8 para a confiança das regras.

2.4 Mineração de Textos e Análise de Sentimentos

A análise de sentimentos dos comentários de clientes da hamburgueria Street Burger, coletados da plataforma iFood, foi estruturada nas seguintes etapas:

1. Coleta e Preparação dos Dados: Os comentários foram carregados manualmente a partir da própria plataforma do Ifood. Foram utilizados três dicionários customizados em português: uma lista de palavras positivas, uma de palavras negativas e uma de *stopwords* (palavras comuns e pontuações a serem ignoradas). A cada comentário foi atribuído um identificador numérico (*id*) único para rastreamento.
2. Pré-processamento e Tokenização: Para preparar o texto para a análise, foram aplicados procedimentos de limpeza e estruturação:
 - Remoção completa da pontuação.
 - Conversão de todo o texto para letras minúsculas para garantir a consistência na contagem.
 - Tokenização, o processo de dividir os comentários em palavras individuais (tokens).
 - Filtragem e remoção das *stopwords* com base no dicionário customizado.

3. Classificação de Sentimentos: Cada token foi classificado ao ser comparado com as listas. Uma palavra foi rotulada como "positiva" se estivesse na lista positiva ou "negativa" se constasse na lista negativa. Palavras não encontradas em nenhuma foram desconsideradas na pontuação.
4. Cálculo do Saldo de Sentimento: Para cada comentário, foi realizada a contagem de palavras positivas e negativas. O sentimento geral foi consolidado na métrica "Saldo":

$$\text{Saldo} = (\text{Total de Palavras Positivas}) - (\text{Total de Palavras Negativas})$$

Em seguida, os resultados foram comparados com a classificação feita pelo Gemini, do Google, onde foi pedido para ele classificar cada comentário em uma escala de -3 a 3.

3 RESULTADOS

3.1 Análise de Clusters

A análise da silhueta média indicou que a divisão dos dados em $k = 2$ clusters é a solução ótima, pois este valor maximizou a largura média da silhueta, como demonstrado na Figura 1.




Figura 1: Análise da silhueta média

A estrutura de agrupamento foi visualmente confirmada pelo dendrograma hierárquico, Figura 2, que exibe uma clara divisão primária dos dados em dois grandes ramos. Com base nessas evidências, os dados foram particionados em dois clusters usando o K-means.




Figura 2: Dendrograma - Agrupamento hierárquico usando distância de Canberra e método de Ward.D

3.2 Regras de Associação

Para identificar os perfis de pacientes mais preditivos de cada grupo, as regras de associação extraídas foram ordenadas de forma decrescente pela métrica **lift**. Esta abordagem privilegia as associações onde a presença das características no antecedente (LHS) mais aumenta a probabilidade de o paciente pertencer a um determinado cluster (RHS).

3.2.1 Perfil do Cluster 1

A análise das regras com maior **lift** revela combinações de atributos que são preditores perfeitos para o Cluster 1. Conforme a Tabela 1, as principais regras apresentam confiança de 100% (**confidence** = 1.0) e um **lift** de aproximadamente 2,13. Isso significa que a presença dessas combinações garante a classificação neste grupo e torna a ocorrência 2,13 vezes mais provável do que o esperado por acaso. A combinação de angina induzida por exercício (**ang.ex=Sim**) e um segmento ST com inclinação plana (**st.slope=Flat**) é um

exemplo de um perfil preditor perfeito para este cluster, além de características como sexo masculino e frequência cardíaca máxima mais baixa

Tabela 1: Top 5 regras de associação para o cluster 1(Ordenadas por Lift)

	LHS (Antecedente)	Suporte	Confiança	Lift	Contagem
1	{ang.ex=Sim, st.slope=Flat}	0.2112	1.0000	2.1338	76
2	{chest.pain=Asymptomatic, ang.ex=Sim, hd=Disease}	0.2310	1.0000	2.1338	70
3	{sex=Male, ang.ex=Sim, hd=Disease}	0.2046	1.0000	2.1338	62
4	{sugar=Normal, ang.ex=Sim, hd=Disease}	0.2046	1.0000	2.1338	62
5	{max.rate=Baixo, st.slope=Flat, hd=Disease}	0.2013	1.0000	2.1338	61

3.2.2 Perfil do Cluster 2

Para o Cluster 2, o **lift** máximo encontrado foi de aproximadamente 1.88. Este grupo é caracterizado primariamente pela ausência de doença cardíaca (**hd=No Disease**), talassemia do tipo normal (**thalassemia=Normal**) e um segmento ST com inclinação ascendente (**st.slope=Up**). A Tabela 2 mostra que a regra de maior **lift** combina frequência cardíaca máxima alta (**max.rate=Alto**), talassemia normal e ausência de doença cardíaca, aumentando em 1.88 vezes a chance de um paciente pertencer ao Cluster 2.

Tabela 2: Top 5 regras de associação para o cluster 2

	LHS (Antecedente)	Suporte	Confiança	Lift	Contagem
1	{max.rate=Alto, thalassemia=Normal, hd=No Disease}	0.2112	1.0000	1.8820	64
2	{age=Baixo, ang.ex=Não, hd=No Disease}	0.2079	1.0000	1.8820	63
3	{age=Baixo, ang.ex=Não, thalassemia=Normal}	0.2079	1.0000	1.8820	63
4	{st.slope=Up, thalassemia=Normal}	0.3036	1.0000	1.8820	92
5	{ang.ex=Não, st.slope=Up, thalassemia=Normal}	0.2442	1.0000	1.8820	74

3.3 Análise de Sentimentos

A análise dos comentários revelou uma percepção geral predominantemente positiva sobre a hamburgueria, embora com pontos de crítica bem definidos, como ilustrado no gráfico de sentimento da Figura 3.




Figura 3: Saldo da análise de sentimento dos comentários

As principais observações extraídas da análise visual são:

- A maioria dos comentários analisados resultou em um saldo de sentimento positivo.
- O comentário 1 ("Hambúrguer muito bom! Amei. A batata frita é simplesmente incrível") apresentou o sentimento mais positivo de toda a amostra, alcançando um saldo de +3.
- A crítica mais forte foi registrada no comentário 32 ("Uma série de erros nesse restaurante. Primeiro que atrasou quase meia hora para chegar. Quando chegou veio o lanche errado, depois demoraram um monte para me responder e trocar o lanche. E quando chegou a carne ainda estava crua, ruim. Não peço mais"), que alcançou o saldo mais negativo, com um valor de -2.

Comparando os resultados obtidos entre esta análise de textos e os obtidos através do Gemini (Figura 4), vemos que o modelo de linguagem do Google, apesar de também mostrar que as avaliações são, em sua maioria, positivas, demonstra uma volatilidade muito maior, o que indica uma maior sensibilidade aos comentários. Isso mostra a diferença de precisão entre um modelo simples de análise de sentimentos e um modelo LLM moderno, como o Gemini.




Figura 4: Comparação resultados Gemini

Em suma, apesar da existência de avaliações negativas que apontam áreas para melhoria, o balanço geral pende para uma experiência satisfatória por parte dos clientes da Street Burger na amostra analisada.

4 CONCLUSÃO

Este trabalho atingiu seus objetivos ao aplicar as técnicas de mineração de dados em dois contextos distintos. Na análise da base *Heart Disease*, a classificação não supervisionada revelou dois perfis de pacientes, com regras de associação destacando características marcantes de cada grupo. Já na segunda parte, a mineração de textos aplicada a comentários do *iFood* sobre a hamburgueria *Street Burger* revelou uma percepção predominantemente positiva dos clientes.

Os resultados mostram a utilidade das técnicas de mineração tanto para dados estruturados quanto para dados textuais, evidenciando seu potencial em diferentes domínios.