

**UNIVERSIDADE ESTADUAL DE MARINGÁ
CENTRO DE CIÊNCIAS EXATAS
CURSO DE ESTATÍSTICA**

**MODELOS MISTOS APLICADOS À PRECISÃO DE EQUIPAMENTOS
HVI NA MENSURAÇÃO DO SFI**

Felipe Yamamoto Tenedine

**Maringá-PR
2026**

FELIPE YAMAMOTO TENEDINE

**MODELOS MISTOS APLICADOS À PRECISÃO DE EQUIPAMENTOS
HVI NA MENSURAÇÃO DO SFI**

Relatório Final de Atividades de Estágio
Supervisionado apresentado como requisito parcial
para a obtenção do título de bacharel em Estatística
pela Universidade Estadual de Maringá.

Orientador: Dr. Vanderly Janeiro.

MODELOS MISTOS APLICADOS À PRECISÃO DE EQUIPAMENTOS HVI NA MENSURAÇÃO DO SFI

Felipe Yamamoto Tenedine

Relatório Final de Atividades de Estágio
Supervisionado apresentado como requisito parcial
para a obtenção do título de bacharel em Estatística
pela Universidade Estadual de Maringá.

Aprovado em: ____/____/____.

BANCA EXAMINADORA

Orientador

Dr. Vanderly Janeiro
Universidade Estadual de Maringá

Membro da banca

Dr. Koki Fernando Oikawa
Universidade Estadual de Maringá

Membro da banca

Dr. Paulo César Ossani
Universidade Estadual de Maringá

RESUMO

Este relatório analisa a precisão de diferentes modelos de equipamentos High Volume Instrument (HVI) na mensuração do Índice de Fibras Curtas (SFI) da fibra de algodão, no âmbito do Programa Standard Brasil HVI (SBRHVI), coordenado pela Associação Brasileira dos Produtores de Algodão (Abrapa). O estudo objetiva verificar se existem diferenças significativas entre as médias dos modelos de máquinas e identificar o impacto de variáveis externas, como idade do equipamento e laboratório, na precisão dos resultados. A metodologia fundamenta-se em estatística descritiva e na aplicação de Modelos Lineares de Efeitos Mistos sobre um conjunto de 8010 medições realizadas por 89 máquinas em 15 laboratórios brasileiros. Os resultados demonstram que o modelo da máquina, a sua idade e as rodadas de referência não exercem efeito significativo sobre o valor médio da medição. Em contrapartida, identifica que a máquina individual e o laboratório responsável pela análise são fatores determinantes para a variabilidade dos dados. O trabalho conclui que o desempenho na medição independe do modelo do equipamento, sendo a variabilidade proveniente de unidades específicas descalibradas ou de condições operacionais de cada laboratório. Por fim, a análise residual indica a necessidade de modelos estatísticos mais flexíveis para capturar adequadamente os valores extremos observados.

Palavras-chave: Estatística. Modelos Mistos. SFI.

Sumário

1	Introdução	1
2	Caracterização da Empresa	2
3	Atividades desenvolvidas	3
4	Estudo das Máquinas	4
4.1	Materiais e Métodos	4
4.2	Resultados	7
4.2.1	Estatística Descritiva	7
4.2.2	Ajuste do Modelo Estatístico	15
4.2.3	Análise dos Resíduos	23
4.3	Conclusão	25
5	Considerações Finais	26
	Referências	27

1 Introdução

O Programa Standard Brasil HVI (SBRHVI), coordenado pela Associação Brasileira dos Produtores de Algodão (Abrapa), tem como objetivo garantir a rastreabilidade dos resultados e assegurar a confiabilidade das avaliações da qualidade da fibra de algodão realizadas por Instrumentos de Alto Volume (High Volume Instrument - HVI). Dessa forma, contribui para aumentar a credibilidade e a transparência dos resultados gerados pelos laboratórios de classificação que operam no Brasil (Associação Brasileira dos Produtores de Algodão, 2026a). Entre os principais indicadores, destacam-se o índice micronaire (MIC), a resistência (STR), o comprimento (UHML), a uniformidade (UI), o índice de fibras curtas (SFI), o grau de reflectância (Rd), o grau de amarelamento (+b), o color grade (CG), entre outros.

Nesse contexto, foi estabelecida uma parceria entre a Abrapa e o Departamento de Estatística da Universidade Estadual de Maringá. A Associação apresentava diversas demandas que poderiam ser atendidas por meio da parceria, como a realização de estudos sobre a qualidade do algodão brasileiro, além de outras análises estatísticas.

2 Caracterização da Empresa

A Abrapa (Associação Brasileira dos Produtores de Algodão) foi criada em 7 de abril de 1999 com sede em Brasília, tendo como propósitos garantir e incrementar a rentabilidade do setor por meio da união e organização dos seus agentes e buscar a sustentabilidade estratégica, atuando política, social e economicamente junto aos setores públicos e privados, sendo a fomentadora da ampliação e melhoria da produção.

Praticando a gestão por resultados, desde o início, a Associação assumiu o compromisso de tornar a cotonicultura brasileira cada vez mais conhecida e competitiva, tanto no cenário nacional quanto internacional. Num trabalho de melhoria contínua, quatro aspectos ganharam destaque ao longo desses anos: qualidade, rastreabilidade, sustentabilidade e promoção.

Representante legítima do setor, é a voz que fala pelos cotonicultores brasileiros, de todos os portes, no Brasil e no mundo. Para melhor cumprir esse papel, é constituída por 11 associações estaduais: Abapa (Bahia); Acopar (Paraná); Agopa (Goiás); Amapa (Maranhão); Amipa (Minas Gerais); Ampa (Mato Grosso); Ampasul (Mato Grosso do Sul); Apaece (Ceará); Apap (Pará); Apipa (Piauí) e Appa (São Paulo). Hoje, a Abrapa representa 99% de toda a área plantada, 99% da produção e 100% da exportação de algodão no Brasil (Associação Brasileira dos Produtores de Algodão, 2026b).

O desempenho das exportações recentes reforça a posição estratégica da Abrapa no setor. Na safra 2023/2024, o Brasil ultrapassou os Estados Unidos e assumiu a liderança mundial nas exportações de algodão (ABRAPA, 2025). Além disso, De acordo com dados da balança comercial consolidados pelo COMEX STAT (ABRAPA e Cotton Brazil, 2026), o saldo acumulado desde a safra 1996/1997 supera US\$ 40,8 bilhões, reflexo de uma trajetória de superávits crescentes ao longo das últimas décadas. No total do período, o Brasil exportou mais de 26 milhões de toneladas, gerando receita superior a US\$ 43,7 bilhões, para 93 países distintos. Na safra mais recente (2024/2025), o saldo foi de US\$ 4,088 bilhões, consolidando mais um ano de forte superávit e confirmando a liderança brasileira no mercado global de algodão.

3 Atividades desenvolvidas

No decorrer do estágio, uma das principais atividades desenvolvidas foi a automação da tabulação de dados de qualidade, com ênfase no cálculo da proporção de fardos em cada faixa dos indicadores divulgados, visando minimizar erros e reduzir o tempo demandado na elaboração dos relatórios. Considerando o expressivo volume de dados envolvido (superior a 44 milhões de fardos ao longo das safras analisadas), todo o processamento e a análise foram realizados no ambiente computacional R (R Core Team, 2025), escolhido por sua capacidade de reprodutibilidade e pelo amplo conjunto de bibliotecas especializadas disponíveis. Para garantir eficiência no tratamento e na análise técnica dos dados, foram empregados os seguintes pacotes: **arrow** (Richardson *et al.*, 2025), utilizado na leitura e filtragem de grandes volumes de dados, permitindo processar milhões de registros com elevado desempenho e baixo custo computacional, o que viabilizou a execução das análises em um notebook local; **tidyverse** (Wickham *et al.*, 2019), responsável pela manipulação, transformação e sumarização dos dados; e **writexl** (Ooms, 2025), empregado na exportação dos resultados tabulados para arquivos no formato **.xlsx**, facilitando sua posterior divulgação pela Abrapa.

Paralelamente à produção dos relatórios mensais de qualidade, surgiu a demanda de compreender o comportamento dos diferentes indicadores ao longo da safra. Para investigar essa variação temporal, recorreu-se a técnicas de Controle Estatístico da Qualidade (CEQ), com destaque para o gráfico de Média Móvel Exponencialmente Ponderada (MMEP), amplamente utilizado no monitoramento contínuo de processos (Montgomery, 2019). Os gráficos foram construídos com o auxílio do pacote **qcc** (Scrucca, 2004) e, atendendo ao interesse da Abrapa, as análises foram organizadas em três recortes distintos: qualidade do algodão brasileiro em âmbito nacional; desempenho por Unidade da Federação (UF); e variação por região do Mato Grosso.

Outra atividade realizada foi uma comparação entre a qualidade do algodão brasileiro com competidores globais, como Estados Unidos e Austrália. Essa comparação focou em tabelas e gráficos das proporções de fardos dentro de cada faixa de qualidade dos principais indicadores. Os resultados dessa análise demonstraram a competitividade da qualidade do algodão brasileiro.

Por fim, uma terceira demanda consistiu em avaliar a confiabilidade das medições realizadas por diferentes modelos de máquinas HVI em diferentes laboratórios, além de

identificar quais fatores poderiam influenciar a precisão dessas mensurações. O indicador selecionado para essa análise foi o Índice de Fibras Curtas (SFI), que expressa a porcentagem de fibras com comprimento inferior a 0,5 polegadas (12,7 mm), sendo que valores mais baixos indicam melhor qualidade, enquanto resultados iguais ou superiores a 10,0 são considerados problemáticos (Cotton South Africa, 2021). O estudo teve como objetivos centrais verificar a existência de diferenças estatisticamente significativas nas médias de medição entre diferentes modelos de máquinas HVI avaliados e identificar as variáveis que melhor explicam a variabilidade do SFI, indicador que se destaca por apresentar maior oscilação em relação aos demais. Dado o escopo e a relevância dessa última análise, o presente relatório concentra-se em detalhar os métodos estatísticos empregados e os resultados obtidos nessa etapa do trabalho.

4 Estudo das Máquinas

4.1 Materiais e Métodos

Os dados foram obtidos por meio de três lotes de amostras para testes cujos valores de SFI eram previamente conhecidos, com o objetivo de comparar o desempenho dos equipamentos. As amostras eram enviadas aos laboratórios, que realizavam as medições e retornavam com os resultados. As análises foram realizadas por 89 máquinas, cada máquina efetuando 30 medições por lote de amostras, totalizando 8010 medições. Participaram 15 laboratórios distribuídos em 5 estados, sendo 1 na Bahia (BA), 1 em Goiás (GO), 1 em Minas Gerais (MG), 2 em Mato Grosso do Sul (MS) e 10 em Mato Grosso (MT)

Inicialmente, foi realizada uma análise exploratória dos dados com o auxílio do pacote `tidyverse` (Wickham *et al.*, 2019), permitindo a organização, a visualização e a sumarização das principais medidas de tendência central e dispersão das variáveis de interesse. Além das estatísticas descritivas, foram calculadas duas métricas amplamente utilizadas para avaliar a precisão das medições: o Erro Absoluto Médio (MAE, *Mean Absolute Error*) e a Raíz do Erro Quadrático Médio (RMSE, *Root Mean Squared Error*). O MAE é definido como a média dos valores absolutos dos desvios de medição:

$$MAE = \frac{1}{n} \sum_{i=1}^n |desvio_i|$$

em que $|desvio_i|$ representa a diferença entre o valor medido e o valor de referência da i -ésima observação. Essa métrica quantifica o afastamento médio das medições em relação ao valor verdadeiro, independentemente da direção do desvio, sendo uma medida direta da precisão do equipamento. Já o RMSE é calculado por:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (desvio_i)^2}$$

sendo mais sensível à presença de desvios extremos, uma vez que são elevados ao quadrado antes da obtenção da média. Dessa forma, o RMSE tende a assumir valores maiores quando existem observações atípicas ou medições com erros elevados.

Na sequência, procedeu-se à modelagem estatística para analisar os fatores associados à variável resposta, definida como a diferença entre o valor medido pela máquina e o valor de referência conhecido do SFI, de forma que valores mais próximos de zero indicam maior precisão da medição.

Para explicar a variação da variável resposta, foram consideradas as seguintes informações, obtidas na Abrapa:

- Modelo da máquina que avaliou a amostra;
- Laboratório no qual a máquina se encontra;
- Idade da máquina;
- Código identificador da máquina;
- Código identificador do lote da amostra.

Devido à alta colinearidade entre as variáveis UF e laboratório, a primeira foi excluída.

Como o interesse direto estava em estudar o efeito do modelo de máquina, do laboratório em que a máquina está instalada e a idade da máquina, essas variáveis foram consideradas de efeito fixo sobre a variável resposta. Já a unidade da máquina e o lote, que podem ter influência na variação da resposta e implicam em dependência da variável resposta, foram consideradas de efeito aleatório. Como o estudo conta com variáveis de efeito fixo e aleatório, a proposta é usar Modelos Lineares de Efeitos Mistos (LMM), como sugerido por Bates *et al.* (2015) e West, Welch e Galecki (2022).

Diferentemente dos modelos de regressão linear clássicos, os LMM são adequados para dados com estrutura de dependência, pois decompõem a variabilidade total em efeitos fixos, associados a fatores cujos impactos se deseja estimar diretamente (modelo da

máquina, laboratório e idade), e efeitos aleatórios, que capturam a correlação intragrupo e a variabilidade não controlada inerente ao processo (máquina individual e lote de referência). Essa abordagem proporciona inferências mais robustas ao modelar de forma realista a estrutura de dependência dos dados, evitando a subestimação dos erros padrão que ocorreria em modelos lineares simples (Pinheiro e Bates, 2000). Dessa forma, o modelo inicial proposto é:

$$Y_{ijlmk} = \mu + \alpha_i + \beta_j + \gamma X_1 + b_l + b_m + \varepsilon_{ijlmk} \quad (1)$$

em que:

- Y_{ijlmk} é a variável resposta (desvio = valor medido - valor conhecido do SFI) observado na k -ésima repetição ($k = 1, \dots, 30$) realizada pela máquina l , pertencente ao modelo de máquina i , no laboratório j , e lote de referência m ;
- μ é a média geral;
- α_i é o efeito fixo do i -ésimo modelo da máquina ($i = 1, 2, 3$);
- β_j é o efeito fixo do j -ésimo laboratório ($j = 1, \dots, 15$);
- X_1 representa a idade da máquina l em anos ($X_1 = 0, \dots, 20$) e γ é o coeficiente de regressão associado;
- b_l é o efeito aleatório da l -ésima máquina ($l = 1, \dots, 89$), com $b_l \sim N(0, \sigma_{\text{maq}}^2)$;
- b_m é o efeito aleatório do m -ésimo lote de referência ($m = 1, \dots, 3$), com $b_m \sim N(0, \sigma_{\text{ref}}^2)$;
- ε_{ijlmk} é o erro aleatório residual, com $\varepsilon_{ijlmk} \sim N(0, \sigma^2)$.

O modelo foi ajustado por meio do pacote **lme4** (Bates *et al.*, 2015). A significância dos efeitos aleatórios foi avaliada por meio do Teste de Razão de Verossimilhança (LRT, do inglês *Likelihood Ratio Test*), implementado na função **ranova()** do pacote *lmerTest* (Kuznetsova, Brockhoff e Christensen, 2017). Nesse procedimento, para cada efeito aleatório, ajusta-se um modelo reduzido e compara-se sua log-verossimilhança restrita (REML) à do modelo completo. Sob a hipótese nula de ausência do efeito, a estatística do teste segue assintoticamente uma distribuição qui-quadrado com 1 grau de liberdade (Self e Liang, 1987).

A significância dos efeitos fixos foi avaliada por meio de testes F com aproximação de Satterthwaite para os graus de liberdade. Essa aproximação é necessária porque, em

modelos mistos, os graus de liberdade do denominador não são inteiros e dependem da estrutura dos dados, de modo que a aproximação de Satterthwaite os estima a partir dos componentes de variância (Kuznetsova, Brockhoff e Christensen, 2017).

Após a seleção do modelo final apenas com os efeitos significativos, as médias marginais estimadas por laboratório foram obtidas com o pacote *emmeans* (Lenth, 2025). Essas médias correspondem às predições do modelo para cada laboratório, com os demais fatores mantidos em seus valores médios. As comparações múltiplas foram realizadas pelo método de Tukey, com agrupamento de letras obtido por meio da função `cld()` do pacote *multcomp* (Hothorn, Bretz e Westfall, 2008).

Todas as análises foram conduzidas no ambiente estatístico *R* (R Core Team, 2025). Por questões de confidencialidade, os nomes dos modelos de máquinas, os identificadores das máquinas e os identificadores dos laboratórios foram substituídos por códigos anônimos.

4.2 Resultados

4.2.1 Estatística Descritiva

De acordo com o levantamento do número de máquinas por modelo, dentre os cinco modelos de máquinas usadas pelos laboratórios, dois deles (Modelo A e Modelo B) eram representados por apenas uma máquina em operação. Em razão da ausência de replicação, esses modelos foram excluídos das análises subsequentes, uma vez que não permitem avaliar de forma adequada a variabilidade entre equipamentos, restando 7830 observações provenientes de 87 máquinas e 3 modelos (Modelos C, D e E).

Os resultados apresentados na Tabela 1 apontam que, em relação ao desvio (variável resposta), as médias indicam comportamentos diferentes entre os três modelos de máquinas, sendo -0.304 para o modelo C, sugerindo tendência à subestimação negativa do SFI. Enquanto os modelos D e E com médias 0.139 e 0.125, respectivamente, apresentam médias mais próximas de zero e leve tendência à superestimação. O resultado é semelhante em se tratando de mediana.

Considerando o valor absoluto do desvio, nota-se que os três modelos de máquinas apresentam desempenho semelhante. Porém, por meio da média, o modelo D tem desempenho superior ao E e C, nesta ordem.

Quanto ao MAE e RMSE, os resultados na Tabela 1 mostram que os três modelos

avaliados apresentaram valores semelhantes para ambas as métricas. O modelo D apresentou os menores valores de MAE (0.706) e RMSE (0.877), enquanto o modelo C apresentou os maiores (MAE = 0.761; RMSE = 1.034). Entretanto, as diferenças observadas foram relativamente pequenas.

Observa-se ainda que, para todos os modelos de máquinas, os valores de RMSE foram superiores aos respectivos valores de MAE. Esse comportamento indica a presença de algumas observações com desvios relativamente elevados em relação ao valor de referência, resultado compatível com o valores extremos observados nos boxplots (Figura 1) e com as amplitudes registradas para o desvio (variável resposta). Apesar disso, as magnitudes das diferenças entre os modelos sugerem desempenho semelhante quanto à precisão das medições.

Em se tratando do desvio padrão, tanto para o desvio das medições quanto para seu valor absoluto, a dispersão observada é relativamente elevada em relação às respectivas médias, sendo um pouco menor no modelo D.

Tabela 1: Estatísticas descritivas do desvio das medições (variável resposta) e seu valor absoluto, por modelo de máquina.

Estatística	Modelo C	Modelo D	Modelo E
Nº obs.	2250	990	4590
Nº máq.	25	11	51
Desvio			
Média	-0.304	0.139	0.125
Desvio-padrão	0.988	0.866	0.933
Mediana	-0.374	0.203	0.097
Mínimo	-6.691	-2.203	-2.891
Máximo	3.897	3.209	6.397
 Desvio 			
Média	0.761	0.706	0.713
Desvio-padrão	0.700	0.520	0.615
Mediana	0.574	0.597	0.574
Mínimo	0.003	0.003	0.003
Máximo	6.691	3.209	6.397
Métricas			
MAE	0.761	0.706	0.713
RMSE	1.034	0.877	0.942




Figura 1: Boxplot dos desvios das medições (a) e seu valor absoluto (b), por modelos de máquinas

A Figura 2 e a Tabela 2 indicam que os diferentes lotes de referência apresentam valores médios e medianos bastante semelhantes em relação ao desvio da medição e seu valor absoluto. Observa-se que, dos três lotes de referência (1311, 1315 e 1362), o lote 1362 possui valores absolutos ligeiramente inferiores em comparação aos demais; contudo, não parece haver diferenças relevantes entre os três lotes de referência.




Figura 2: Boxplot dos desvios das medições(a) e seu valor absoluto (b), por lote de referência

Tabela 2: Estatísticas descritivas do desvio das medições e seu valor absoluto, por lote de referência.

Estatística	Ref. 1311	Ref. 1315	Ref. 1362
Nº obs.	2610	2610	2610
Nº máq.	87	87	87
Desvio			
Média	0.014	-0.008	0.005
Desvio-padrão	1.039	0.956	0.883
Mediana	-0.103	0.009	0.026
Mínimo	-4.203	-6.691	-4.074
Máximo	6.397	3.509	2.926
 Desvio 			
Média	0.799	0.717	0.661
Desvio-padrão	0.663	0.632	0.586
Mediana	0.603	0.591	0.474
Mínimo	0.003	0.009	0.026
Máximo	6.397	6.691	4.074
Métricas			
MAE	0.799	0.717	0.661
RMSE	1.039	0.956	0.883

A Figura 3 e a Tabela 3 mostram que o estado de Goiás apresenta os menores valores de média e mediana para o valor absoluto do desvio da medição. Por outro lado,

as medições realizadas no Mato Grosso (MT) apresentam média do desvio mais próxima de zero, embora acompanhada de maior variabilidade, evidenciada pelo desvio-padrão mais elevado. De modo geral, não se observa um padrão consistente de diferenças entre os modelos de máquinas dentro de cada estado, exceto pela presença de alguns valores extremos nos estados da Bahia e do Mato Grosso. Além disso, verifica-se que a maioria dos estados não possui todos os modelos de máquinas em operação e quantidade de máquinas é muito diferente em cada Estado, o que limita comparações mais abrangentes entre eles.




Figura 3: Boxplot dos desvios das medições(a) e seu valor absoluto (b) por UF

A dispersão observada na Figura 4 aponta ausência de um padrão sistemático entre a idade da máquina e o desvio das medições. A linha de tendência permanece praticamente horizontal, indicando que a idade do equipamento não exerce influência aparente sobre seu desempenho. Observa-se, contudo, que as máquinas mais novas pertencem predominantemente ao modelo D, enquanto as mais antigas são majoritariamente do modelo E. Para facilitar a visualização de observações sobrepostas, foi aplicado um deslocamento de 0.1 unidade na variável idade, subtraindo-se esse valor para as máquinas do modelo C e adicionando-o para as máquinas do modelo E.

Tabela 3: Estatísticas descritivas do desvio das medições e seu valor absoluto, por lote de referência.

Estatística	BA	GO	MG	MS	MT
Nº obs.	1440	540	180	540	5130
Nº máq.	16	6	2	6	57
Desvio					
Média	0.271	0.262	0.738	0.603	-0.188
Desvio-padrão	0.955	0.714	0.636	0.661	0.959
Mediana	0.226	0.209	0.697	0.597	-0.203
Mínimo	-2.503	-1.491	-0.703	-1.291	-6.691
Máximo	6.397	3.209	3.197	2.897	4.297
 Desvio 					
Média	0.759	0.573	0.798	0.717	0.731
Desvio-padrão	0.639	0.500	0.559	0.535	0.649
Mediana	0.609	0.474	0.697	0.609	0.574
Mínimo	0.003	0.003	0.003	0.003	0.003
Máximo	6.397	3.209	3.197	2.897	6.691
Métricas					
MAE	0.759	0.573	0.798	0.717	0.731
RMSE	0.992	0.760	0.973	0.894	0.977




Figura 4: Dispersão dos desvios das medições em função da idade da máquina

Através do detalhamento por máquina na Figura 5, verifica-se que a variabilidade é fortemente influenciada por unidades específicas. Enquanto a maioria das máquinas opera dentro de uma faixa de desvio estreita, algumas unidades isoladas são responsáveis por

quase todos os valores atípicos, principalmente dos modelos C e E. Além disso, há uma máquina do modelo C que parece descalibrada em relação às medidas apresentadas pelas demais. Portanto, essa máquina não será considerada para ajuste do modelo estatístico.




Figura 5: Boxplot dos desvios das medições por máquina, dividido por modelo de máquina

O detalhamento por laboratório na Figura 6 mostra que alguns laboratórios tendem a subestimar o verdadeiro valor, enquanto outros tendem a superestimá-lo. Observa-se também que determinados laboratórios possuem maior quantidade de valores atípicos, sugerindo maior variabilidade nas medições realizadas. Esses resultados indicam diferenças tanto na média quanto na variabilidade da medição entre os laboratórios.




Figura 6: Boxplot dos desvios das medições por laboratório.

Por fim, as densidades apresentadas na Figura 7 deixam mais evidentes as diferenças entre os modelos de máquinas do que as estatística descritivas. Enquanto os modelos D e E apresentam distribuições do desvio das medições centradas próximas de zero, o modelo C mostra deslocamento para valores negativos, indicando tendência de subestimação. Essa diferença é consistente com as médias dos desvios observadas na Tabela 1. Em termos de dispersão, os três modelos apresentam comportamento semelhante, embora o modelo D tenha apresentado os melhores valores de desvio-padrão e RMSE.




Figura 7: Densidade dos desvios das medições de cada modelo de máquina.

4.2.2 Ajuste do Modelo Estatístico

Com base nas observações realizadas na exploração dos dados, há indícios de que o modelo de regressão linear de efeitos mistos (1) proposto é um bom candidato para descrever os valores de erros de medição observados na Figura 7, visto que a variável resposta (desvio das medições) é contínua e pode assumir valores positivos e negativos. Além disso, há uma estrutura de dependência entre observações (medidas repetidas por uma mesma máquina).

O primeiro passo no ajuste desse tipo de modelo é investigar quais componentes de variância devem estar no modelo estatístico, conforme sugestão de West, Welch e Galecki (2022). Para isso, foi inicialmente ajustado o modelo M_0 , contendo todos os efeitos fixos e aleatórios especificados na Equação 1. As Variáveis consideradas no modelo estatístico para predizer o erro de medida foram:

- Variáveis de efeito aleatório:
 - **ref**: número de referência do lote da amostra enviada para aferição;
 - **maquina**: efeito da máquina específica que realizou a análise da amostra.
- Variáveis de efeito fixo:
 - **modelo**: o modelo da máquina que realizou a medida do SFI;

- **laboratorio**: laboratório no qual a máquina está instalada;
- **idade**: idade da máquina.

As estimativas dos componentes de variância são apresentadas na Tabela 4. Observa-se que $\sigma_{ref}^2 \approx 0$, sugerindo que a variância devido a **ref** não é significativa.

Tabela 4: Componentes de variância estimados para o modelo misto.

Grupo	Variância	Desvio-Padrão	IC 95% Inferior	IC 95% Superior
Máquina	0.2694	0.5191	0.1588	0.2925
Ref	0.0000	0.0000	0.0000	0.0018
Residual	0.4889	0.6992	0.4738	0.5045

Para testar a significância de σ_{ref}^2 e σ_{maq}^2 , foram ajustados modelos sem esses componentes de variância, M_1 e M_2 , respectivamente. Os modelos M_1 e M_2 foram ajustados usando máxima verossimilhança restrita (REML) e testados em relação ao modelo M_0 usando o teste de razão de verossimilhança (Tabela 5).

Tabela 5: Teste de razão de verossimilhança para os efeitos aleatórios.

Modelo	Termo removido	npar	logLik	AIC	LRT	gl	Valor- <i>p</i>	Teste
M_0	Modelo Completo	21	−8481.5	17005	—	—	—	—
M_1	(1 <i>ref</i>)	20	−8481.5	17003	0.0	1	1	anova(M_1 , M_0)
M_2	(1 <i>maquina</i>)	20	−9765.2	19570	2567.5	1	< 0.001	anova(M_2 , M_0)

npar: número de parâmetros; logLik: log-verossimilhança restrita (REML);

LRT: estatística do teste de razão de verossimilhança; gl: graus de liberdade.

Os resultados obtidos na Tabela 5 indicam que:

- **ref**: não é significativo para o modelo estatístico (valor-*p* ≈ 1), ou seja, não há evidências para rejeitar a hipótese nula de que $\sigma_{ref}^2 = 0$. Logo, a variabilidade existente nos lotes do material referência não é “importante” para a variabilidade dos resultados. As três amostras de referência são materiais padronizados justamente para verificar a precisão das medições dos equipamentos. Se o programa da Abrapa está funcionando adequadamente, espera-se que os lotes de referência não introduzam variabilidade relevante, explicando $\sigma_{ref}^2 \approx 0$;

- **maquina:** é significativo (valor-p < 0.001; $\sigma_{maq}^2 \neq 0$), ou seja, o efeito da máquina específica que realizou a análise da amostra exerce um peso sobre a variabilidade dos dados. Existem máquinas com variabilidade excessiva nos resultados apresentados (falta precisão).

Os componentes de variância estimados (Tabela 6) no novo modelo indicam que a variabilidade total nas medições do SFI pode ser decomposta em duas fontes: a variação entre máquinas ($\hat{\sigma}_{maq}^2 = 0.261$) e a variação residual ($\hat{\sigma}^2 = 0.489$). O Índice de Correlação Intraclass (ICC), dado por $ICC = \hat{\sigma}_{maq}^2 / (\hat{\sigma}_{maq}^2 + \hat{\sigma}^2) \approx 0.348$, indica que aproximadamente 35% da variabilidade total é explicada pelas diferenças entre as máquinas individuais, independentemente do laboratório em que estão instaladas.

Tabela 6: Componentes de variância dos efeitos aleatórios.

Grupo	Efeito	Variância	Desvio Padrão
maquina	Intercepto	0.261	0.511
Resíduo	—	0.489	0.699

$n = 7830$ observações; 87 máquinas.

Em seguida, a significância dos efeitos fixos foi avaliada por meio de uma análise de variância (ANOVA), utilizando testes F com correção dos graus de liberdade pelo método de Satterthwaite. Os resultados na Tabela 7 apontaram que:

- **modelo** não é significativo (valor-p = 0.723), ou seja, o modelo da máquina que realizou a medida do SFI não tem efeito importante sobre o valor médio medido;
- **laboratório** é significativo (valor-p < 0.001), ou seja, o laboratório no qual a máquina está instalada exerce papel importante em relação ao valor médio do SFI;
- **idade** não é significativo para o modelo (valor-p = 0.934), ou seja, a idade da máquina não está afetando o valor médio de SFI.

Tabela 7: Teste F com aproximação de Satterthwaite para os efeitos fixos.

Variável	SQ	QM	NumDF	DenDF	F	Valor- <i>p</i>
Modelo	0.318	0.159	2	69.001	0.326	0.723
Laboratório	28.087	2.006	14	69.001	4.104	< 0.001
Idade	0.003	0.003	1	69.001	0.0068	0.934

SQ: soma de quadrados; QM: quadrado médio; NumDF: gl do numerador;

DenDF: gl do denominador (Satterthwaite).

Diante desses resultados, o modelo final ajustado, após a remoção dos termos não significativos, foi:

$$\hat{Y}_{jl} = \hat{\mu} + \hat{\beta}_j + \tilde{b}_l$$

em que $\hat{\mu} = -0.1766$ é a média estimada para o laboratório de referência (Lab 01), $\hat{\beta}_j$ é a diferença entre a média do j -ésimo laboratório em relação à média do Lab 01, e $\tilde{b}_l$ é o valor predito para o efeito da l -ésima máquina. Expandindo com os coeficientes estimados:

$$\begin{aligned} \hat{Y}_{jl} = & -0.1766 \\ & + \underbrace{(0.9142 \cdot \mathbf{I}_{\text{Lab02}} - 0.6903 \cdot \mathbf{I}_{\text{Lab03}} + 0.0248 \cdot \mathbf{I}_{\text{Lab04}} + 0.4473 \cdot \mathbf{I}_{\text{Lab05}} + 0.7339 \cdot \mathbf{I}_{\text{Lab06}})}_{\hat{\beta}_j \text{ (laboratório)}} \\ & + \underbrace{(0.4492 \cdot \mathbf{I}_{\text{Lab07}} + 0.8928 \cdot \mathbf{I}_{\text{Lab08}} - 0.1157 \cdot \mathbf{I}_{\text{Lab09}} - 0.6608 \cdot \mathbf{I}_{\text{Lab10}} + 0.4388 \cdot \mathbf{I}_{\text{Lab11}})}_{\hat{\beta}_j \text{ (laboratório)}} \\ & + \underbrace{(-0.0439 \cdot \mathbf{I}_{\text{Lab12}} + 0.5537 \cdot \mathbf{I}_{\text{Lab13}} - 0.0447 \cdot \mathbf{I}_{\text{Lab14}} - 0.1413 \cdot \mathbf{I}_{\text{Lab15}})}_{\hat{\beta}_j \text{ (laboratório)}} + \tilde{b}_l \end{aligned} \quad (2)$$

em que $\mathbf{I}_{(\cdot)}$ é a função indicadora que assume valor 1 quando a observação pertence ao laboratório indicado e 0 caso contrário, sendo Lab 01 a categoria de referência.

Dado que o efeito aleatório de máquina foi significativo, realizou-se a predição do efeito de cada equipamento sobre o valor médio do SFI. Os valores preditos ($\tilde{b}_l$) são apresentados na Tabela 8 e ilustrados com seus respectivos intervalos de confiança de 95% na Figura 8. Observa-se que a Maq 40 é a que mais se afasta da média geral, subestimando o valor do SFI ($\tilde{b}_l = -1.987$), enquanto a Maq 36 é a que mais superestima ($\tilde{b}_l = 1.217$), o que é consistente com a parcela expressiva de variabilidade atribuída às máquinas individuais evidenciada pelo ICC. Além disso, observa-se na Tabela 9 que, entre as cinco máquinas com efeito aleatório predito ($\tilde{b}_l$) superior a 1 em valor absoluto, três

pertencem ao modelo E. Dentre essas, duas estão alocadas no laboratório 05, sugerindo a existência de máquinas com comportamento particularmente distinto da média geral nesse laboratório. Esse resultado reforça a importância de considerar a variabilidade entre máquinas individuais e investigar com mais cuidado o porquê dessa variabilidade maior nesse laboratório em específico.

Tabela 8: Efeitos aleatórios preditos por máquina ($\tilde{b}_l$).

Máquina	$\tilde{b}_l$	Máquina	$\tilde{b}_l$	Máquina	$\tilde{b}_l$
Maq 01	-0.041	Maq 31	-0.722	Maq 60	-0.155
Maq 02	0.041	Maq 32	0.772	Maq 61	0.377
Maq 03	0.073	Maq 33	-0.437	Maq 62	0.000
Maq 05	-0.109	Maq 34	-0.197	Maq 63	0.000
Maq 06	0.120	Maq 35	0.428	Maq 65	-0.410
Maq 07	0.203	Maq 36	1.217	Maq 66	0.645
Maq 08	0.086	Maq 37	0.263	Maq 67	0.149
Maq 09	-0.065	Maq 38	0.344	Maq 68	-0.104
Maq 10	-0.513	Maq 39	0.297	Maq 69	0.453
Maq 11	0.187	Maq 40	-1.987	Maq 70	-0.251
Maq 12	-0.183	Maq 41	0.115	Maq 71	-0.240
Maq 13	0.163	Maq 42	-0.311	Maq 72	0.293
Maq 14	0.201	Maq 43	-0.242	Maq 73	-0.115
Maq 15	-0.162	Maq 44	-1.064	Maq 74	-0.094
Maq 16	0.287	Maq 45	-0.120	Maq 75	-0.095
Maq 17	0.273	Maq 46	0.060	Maq 76	0.093
Maq 18	-0.238	Maq 47	0.234	Maq 77	0.232
Maq 19	0.330	Maq 48	-0.122	Maq 78	-0.231
Maq 20	0.419	Maq 49	-0.463	Maq 79	-0.099
Maq 21	0.311	Maq 50	-0.238	Maq 80	0.552
Maq 22	0.000	Maq 51	0.608	Maq 81	-0.295
Maq 23	-0.365	Maq 52	0.067	Maq 82	-0.279
Maq 24	-0.048	Maq 53	0.795	Maq 83	0.542
Maq 25	0.192	Maq 54	0.134	Maq 84	0.062
Maq 26	0.072	Maq 55	0.347	Maq 85	-0.132
Maq 27	-0.097	Maq 56	-0.154	Maq 86	-1.419
Maq 28	0.444	Maq 57	-0.127	Maq 87	-0.522
Maq 29	0.022	Maq 58	0.080	Maq 88	0.508
Maq 30	-1.354	Maq 59	0.185	Maq 89	0.525




Figura 8: Valores preditos do efeito de medição do SFI por máquina

Tabela 9: Máquinas com efeito aleatório predito $|\tilde{b}_l| > 1$.

Máquina	Laboratório	Modelo	$\tilde{b}_l$
Maq 40	Lab 03	Modelo C	-1.987
Maq 86	Lab 05	Modelo D	-1.419
Maq 30	Lab 12	Modelo E	-1.354
Maq 36	Lab 05	Modelo E	1.217
Maq 44	Lab 05	Modelo E	-1.064

Na Tabela 10 são apresentadas as médias marginais estimadas por laboratório para a variável resposta e o resultado das comparações múltiplas entre valores médios de SFI. Na coluna “Grupo”, os laboratórios com letras iguais não apresentaram diferença significativa nas médias apresentadas pelos mesmos. Por exemplo, os laboratórios 02, 08, 06, 05 e 11 não diferem entre si, mas diferem do laboratório 03. Os resultados desta tabela também estão representados na Figura 9. É importante ressaltar que os laboratórios com maior intervalo de confiança para a média marginal estimada (laboratórios 4, 7 e 10) são os que apresentam uma única máquina para medição, resultando em maior incerteza.

Tabela 10: Médias marginais estimadas (emmeans) por laboratório, com IC 95% e agrupamento por letras.

Laboratório	Média Estimada	IC inferior	IC superior	Grupo
Lab 02	0.738	0.022	1.453	ab
Lab 08	0.716	0.211	1.222	ab
Lab 06	0.557	0.265	0.849	a
Lab 13	0.377	-0.338	1.092	abc
Lab 07	0.273	-0.739	1.284	abc
Lab 05	0.271	0.018	0.524	ab
Lab 11	0.262	-0.151	0.675	ab
Lab 04	-0.152	-1.163	0.860	abc
Lab 01	-0.177	-0.559	0.206	abc
Lab 12	-0.221	-0.633	0.192	abc
Lab 14	-0.221	-0.727	0.284	abc
Lab 09	-0.292	-0.650	0.065	bc

Laboratório	Média Estimada	IC inferior	IC superior	Grupo
Lab 15	-0.318	-0.700	0.064	bc
Lab 10	-0.837	-1.849	0.174	abc
Lab 03	-0.867	-1.187	-0.547	c




Figura 9: Médias marginais estimadas (emmeans) por laboratório, com IC 95% e agrupamento por letras.

4.2.3 Análise dos Resíduos

O gráfico quantil-quantil dos resíduos, apresentado na Figura 10b, indica desvios da suposição de normalidade nas caudas da distribuição, com a presença de observações mais extremas do que as previstas pelo modelo Normal. Esse comportamento sugere que modelos mistos com distribuições residuais mais robustas, como a distribuição t de

Student, poderiam proporcionar melhor acomodação desses valores extremos. Entretanto, parte desses desvios pode estar associada ao comportamento atípico de algumas máquinas específicas, conforme evidenciado na Figura 10a.

Por sua vez, a Figura 10c não revela padrões sistemáticos na relação entre resíduos e valores ajustados, indicando que a estrutura média especificada pelo modelo é adequada para descrever os dados. Ainda assim, observa-se a presença de resíduos padronizados inferiores a -3 e superiores a 3, reforçando a existência de observações atípicas.

Finalmente, a Figura 10d mostra dispersão considerável dos valores ajustados em torno da reta identidade, sugerindo que uma parcela da variabilidade observada não é completamente explicada pelo modelo. Embora tais desvios não comprometam de forma substancial as inferências, especialmente em razão do grande tamanho amostral, eles indicam que abordagens mais robustas ou estratégias alternativas de modelagem podem proporcionar melhor ajuste aos dados, particularmente na presença de observações extremas.




Figura 10: Análise dos resíduos do modelo final ajustado

4.3 Conclusão

A análise dos efeitos fixos indicou que o modelo da máquina não apresentou efeito significativo sobre o desvio médio das medições do SFI (valor- $p = 0.723$), sugerindo que, em média, os diferentes modelos de equipamentos HVI produzem medições equivalentes, apesar de o Modelo D apresentar menor variabilidade, como observado na Tabela 1. De forma semelhante, a idade da máquina também não se mostrou relevante (valor- $p = 0.934$), sendo removida do modelo final. Por outro lado, o laboratório exerceu efeito significativo (valor- $p < 0.001$), evidenciando que há diferenças entre os ambientes de medição.

Entre os efeitos aleatórios, o lote de referência não se mostrou importante para a variabilidade dos desvios de medição (valor- $p \approx 1$), ao passo que a máquina individual mostrou-se altamente relevante (valor- $p < 0.001$), indicando que parte substancial da variabilidade nas medições é atribuída às particularidades de cada equipamento.

No entanto, a análise dos resíduos (Figura 10) revelou a presença de valores extremos não adequadamente capturados pelo modelo ajustado, o que sugere limitações na sua capacidade de representação da estrutura dos dados. Embora esses valores atípicos não comprometam de forma substancial as inferências devido ao grande tamanho amostral, sugere-se como desdobramento do estudo:

- Avaliar modelos mistos com distribuição t de Student, visando acomodar melhor os valores extremos observados nos resíduos;
- Investigar o uso de erro absoluto com a variável resposta, direcionando a análise para a precisão das medições, independente da direção do erro;
- Considerar medidas de erro relativo como variável resposta, permitindo quantificar o erro de forma proporcional ou percentual em relação ao valor de referência;
- Explorar estruturas de variância residual mais complexas e possíveis interações entre as variáveis independentes disponíveis.

5 Considerações Finais

O estágio na Abrapa foi muito importante para aproximar a teoria aprendida em sala de aula da prática do mercado de trabalho. Trabalhar com um conjunto real de dados, trouxe um senso de responsabilidade que vai além do que é visto em sala de aula. A estatística deixou de ser apenas um conteúdo teórico e passou a ser uma ferramenta essencial para garantir a qualidade e a credibilidade de um setor tão relevante como o da exportação de algodão no Brasil.

Um aprendizado fundamental foi a comunicação dos resultados. Nem sempre termos técnicos fazem sentido para quem toma decisões. Por isso, foi importante transformar análises estatísticas em informações mais claras e diretas.

Além disso, trabalhar com dados reais reforçou a importância do olhar crítico. Identificar possíveis problemas, como máquinas descalibradas, e entender as limitações dos modelos ajudou a desenvolver uma visão mais prática da estatística.

Ao final do estágio, ficou claro que a graduação forneceu a base teórica, enquanto a experiência prática trouxe mais segurança para atuar profissionalmente. Hoje me sinto mais preparado para aplicar a estatística de forma objetiva, contribuindo para a tomada de decisões de forma eficiente.

Referências

ABRAPA. **Brasil bate recorde de exportações no ano comercial 2024/2025 e se consolida como maior exportador mundial de algodão** Associação Brasileira dos Produtores de Algodão, 2025. Disponível em: <<https://abrapa.com.br/2025/08/21/brasil-bate-recorde-de-exportacoes-no-ano-comercial-2024-2025-e-se-consolida-como-maior-exportador-mundial-de-algodao/>>

ABRAPA; COTTON BRAZIL. **Evolução da Balança Comercial Anual de Algodão do Brasil e UF (US\$)** Associação Brasileira dos Produtores de Algodão, 2026. Disponível em: <<https://app.powerbi.com/view?r=eyJrIjoiZDZhZTg1NDMtNTlkYi00ZmJmLWUwNmEtN>

ASSOCIAÇÃO BRASILEIRA DOS PRODUTORES DE ALGODÃO. **SBRHVI – Programa Standard Brasil HVI**. Disponível em: <<https://abrapa.com.br/qualidade/sbrhvi-programa-standard-brasil-hvi/>>. Acesso em: 14 mar. 2026a.

_____. **Quem Somos**. Disponível em: <<https://abrapa.com.br/quem-somos/>>.

BATES, D. *et al.* **Fitting Linear Mixed-Effects Models Using lme4**. **Journal of Statistical Software**, v. 67, n. 1, p. 1–48, 2015.

COTTON SOUTH AFRICA. **Cotton Quality Report: 2019/2020 Production Season**. [s.l.] Cotton SA, mar. 2021. Disponível em: <<https://cottonsa.org.za/wp-content/uploads/2021/03/KSA-7.5-Dok.-6a-Cotton-Quality-Report-2019-2020-Production-Season-final-final.pdf>>.

HOTHORN, T.; BRETZ, F.; WESTFALL, P. Simultaneous Inference in General Parametric Models. **Biometrical Journal**, v. 50, n. 3, p. 346–363, 2008.

KUZNETSOVA, A.; BROCKHOFF, P. B.; CHRISTENSEN, R. H. B. **lmerTest Package: Tests in Linear Mixed Effects Models**. **Journal of Statistical Software**, v. 82, n. 13, p. 1–26, 2017.

LENTH, R. V. **emmeans: Estimated Marginal Means, aka Least-Squares Means**. [s.l.: s.n.].

MONTGOMERY, D. C. **Introduction to Statistical Quality Control**. 8. ed. [s.l.] John Wiley & Sons, 2019.

OOMS, J. **writexl: Export Data Frames to Excel 'xlsx' Format**. [s.l.: s.n.].

PINHEIRO, J. C.; BATES, D. M. **Mixed-Effects Models in S and S-PLUS**. New York: Springer, 2000.

R CORE TEAM. **R: A Language and Environment for Statistical Computing**.

- Vienna, Austria: R Foundation for Statistical Computing, 2025.
- RICHARDSON, N. *et al.* **arrow: Integration to 'Apache' 'Arrow'**. [s.l: s.n.].
- SCRUCCA, L. **qcc: an R package for quality control charting and statistical process control**. **R News**, v. 4/1, p. 11–17, 2004.
- SELF, S. G.; LIANG, K.-Y. **Asymptotic Properties of Maximum Likelihood Estimators and Likelihood Ratio Tests under Nonstandard Conditions**. **Journal of the American Statistical Association**, v. 82, n. 398, p. 605–610, 1987.
- WEST, B. T.; WELCH, K. B.; GALECKI, A. T. **Linear Mixed Models: A Practical Guide Using Statistical Software**. 3rd. ed. Boca Raton: Chapman; Hall/CRC, 2022.
- WICKHAM, H. *et al.* **Welcome to the tidyverse**. **Journal of Open Source Software**, v. 4, n. 43, p. 1686, 2019.