

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Desempenho no ENEM e Condições Socioeconômicas: Uma
Análise via Regressão Linear Múltipla

Sumário

1	INTRODUÇÃO	1
2	METODOLOGIA	1
2.1	Dados	1
2.2	Análise Estatística	2
2.2.1	Análise Exploratória e Medidas de Associação	2
2.2.2	Modelo de Regressão e Seleção de Variáveis	2
2.2.3	Diagnóstico do Modelo	3
3	RESULTADOS	3
3.1	Análise Exploratória	3
3.2	Modelo de Regressão Linear Múltipla	5
3.3	Diagnóstico do Modelo	8
4	CONCLUSÃO	8
5	ANEXO	10
	REFERÊNCIAS	17

1 INTRODUÇÃO

O Exame Nacional do Ensino Médio (ENEM) é o principal mecanismo de acesso ao ensino superior no Brasil e uma ferramenta de avaliação do conhecimento adquirido pelos estudantes na educação básica. Os dados gerados pelo ENEM constituem uma fonte valiosa para a pesquisa sobre desigualdades educacionais (Lima e Brighenti, 2023). A literatura acadêmica tem consistentemente demonstrado que o desempenho dos estudantes está profundamente associado às condições socioeconômicas, familiares e escolares em que estão inseridos.

Estudos empíricos no Brasil mostram que os recursos familiares, incluindo o nível de instrução dos pais, são determinantes para o desempenho cognitivo dos estudantes, o que se reflete nos resultados de avaliações em larga escala como o ENEM (Soares e Collares, 2006). Este padrão sugere que recursos disponíveis no ambiente doméstico, tanto materiais quanto intelectuais, conferem vantagens significativas aos estudantes.

Este trabalho surgiu da curiosidade em entender os determinantes do desempenho dos estudantes de Maringá no ENEM 2023. O objetivo é realizar análises descritivas e construir um modelo estatístico de regressão para identificar quais fatores socioeconômicos, dentre os coletados pelo questionário do INEP, melhor predizem o desempenho geral dos estudantes locais no ENEM 2023.

2 METODOLOGIA

2.1 Dados

Foram utilizados os Microdados do ENEM 2023 (INEP). A amostra foi delimitada a partir dos seguintes critérios de inclusão: (i) estudantes cuja escola de conclusão do Ensino Médio estava sediada em Maringá e cuja prova também foi realizada na cidade; (ii) conclusão do Ensino Médio em 2023; (iii) presença confirmada em todos os dias de prova; e (iv) nota superior a 100 em cada uma das quatro áreas de conhecimento. Essa nota mínima foi utilizada para excluir provas em branco, com pouquíssimas respostas ou com comportamento inconsistente nas respostas, visto que o ENEM utiliza a teoria de resposta ao item, que penaliza respostas inconsistentes, como acertar questões difíceis e errar as

fáceis (INEP, 2021). A amostra final consolidou-se em 1.765 observações. A variável de interesse foi a média aritmética das notas das quatro provas objetivas (Ciências Humanas, Ciências da Natureza, Linguagens e Códigos e Matemática) e as variáveis independentes utilizadas são as dispostas na Tabela 2.

2.2 Análise Estatística

A análise foi realizada no ambiente estatístico R (R Core Team, 2025). A estratégia analítica foi dividida em duas fases: exploratória e de modelagem.

2.2.1 Análise Exploratória e Medidas de Associação

Para mensurar a força da associação entre os dados do questionário socioeconômico (questões Q001 a Q025), calculou-se o **V de Cramér** e o índice **Eta-quadrado** (η^2).

O V de Cramér é baseado na estatística qui-quadrado (χ^2). Seu valor varia de 0 (nenhuma associação) a 1 (associação perfeita) e é dado por (Cramér, 1946):

$$V = \sqrt{\frac{\chi^2}{n \cdot (\min(k, r) - 1)}}$$

no qual n é o total de observações, k é o número de colunas e r é o número de linhas na tabela de contingência.

Além dele, para avaliar a relação entre cada preditor categórico do questionário socioeconômico e a variável de desfecho numérica, empregou-se o **Eta-quadrado** (η^2), que é interpretado como a proporção da variância nas notas explicada pelo fator socioeconômico, funcionando como uma medida de tamanho de efeito (Bakeman, 2005).

2.2.2 Modelo de Regressão e Seleção de Variáveis

Foi ajustado um modelo de regressão linear múltipla. Para a seleção de um subconjunto parcimonioso de preditores, utilizou-se o procedimento *stepwise* bidirecional, que visa minimizar o **Critério de Informação de Akaike (AIC)** (Akaike, 1974). O AIC oferece um balanço entre a bondade de ajuste do modelo e sua complexidade. O valor do AIC é

obtido pela equação:

$$AIC = 2k - 2\ln(\hat{L})$$

sendo k o número de parâmetros estimados e $\hat{L}$ o valor máximo da função de verossimilhança. O uso do AIC na seleção de modelos é uma prática consolidada que favorece a parcimônia (Burnham e Anderson, 2002).

Após a seleção dos preditores via procedimento stepwise com base no AIC, foi realizada uma análise de multicolinearidade por meio do Fator de Inflação da Variância (VIF) (Montgomery, Peck e Vining, 2021).

2.2.3 Diagnóstico do Modelo

A adequação do modelo foi avaliada por meio de gráficos de diagnóstico, especialmente os gráficos half-normal com envelopes de simulação, construídos com o pacote `hnp` no R. Essa abordagem se mostrou bastante útil, pois permite visualizar de forma clara o comportamento dos resíduos esperados sob o modelo ajustado. Quando os resíduos observados permanecem, em grande parte, dentro dos limites definidos pelos envelopes, temos uma boa indicação de que o modelo está descrevendo os dados de maneira satisfatória. Diferentemente de testes estatísticos formais que, em amostras grandes, podem indicar problemas mesmo diante de desvios pouco relevantes, esse método gráfico proporciona uma avaliação mais prática e intuitiva da qualidade do ajuste (Moral, Hinde e Demétrio, 2017).

3 RESULTADOS

3.1 Análise Exploratória

A análise exploratória dos dados revelou alguns padrões interessantes. Como mostra a Figura 1, as notas das quatro áreas e a média geral apresentam distribuições distintas. Dentre elas, a disciplina de Matemática se destaca por apresentar a maior variabilidade, o que sugere uma maior diversidade no desempenho dos estudantes. Em contrapartida, as notas de Linguagens e Códigos demonstram menor dispersão, com valores mais concentrados em torno da média. Além disso, a distribuição da média geral das notas

se aproxima bastante de uma curva normal, característica que reforça sua escolha como variável resposta para o modelo de regressão.




Figura 1: Distribuição das Notas por Disciplina.

A análise das associações entre as variáveis do questionário socioeconômico, representada pelo V de Cramér na Figura 2, evidencia a interconexão entre diferentes aspectos do status socioeconômico. As relações mais intensas são observadas nas variáveis referentes à renda familiar (Q006) e ao número de banheiros no domicílio (Q008), sugerindo que, embora distintas, essas medidas estão fortemente correlacionadas e refletem, em grande parte, o nível de renda familiar.

A Figura 3, que exibe o Eta-quadrado (η^2), quantifica a importância de cada questão socioeconômica para explicar a variação das notas. Fica evidente que as variáveis de capital familiar são as mais influentes.

Além disso, a escolaridade da mãe (Q002), a escolaridade do pai (Q001) e a renda familiar (Q006) se destacam com as maiores barras de cor vermelha intensa e cinza em todas as disciplinas, indicando que, isoladamente, são os fatores com maior poder preditivo.

Além dessas, outra variável que chama atenção é a quantidade de computadores em




Figura 2: Matriz de Correlação (V de Cramér) entre Variáveis Socioeconômicas.

casa (Q024), que pode estar relacionado à renda, mas também pode mostrar a diferença que faz a tecnologia nos estudos e desempenho no ENEM.

3.2 Modelo de Regressão Linear Múltipla

Após a etapa de seleção de variáveis, o modelo final de regressão linear múltipla apresentou um R^2 ajustado de 0,3124. Isso indica que os preditores escolhidos explicam aproximadamente 31,2% da variação nas notas médias dos estudantes — um valor que, embora modesto à primeira vista, é compatível com o que se espera em pesquisas na área de ciências sociais (Ozili, 2022). O teste F global foi altamente significativo ($p < 0,001$), o que reforça a relevância estatística do modelo como um todo. Além disso, todos os preditores exibiram valores de VIF inferiores a 5, o que sugere ausência de multicolinearidade preocupante e garante maior confiabilidade às estimativas dos coeficientes (Montgomery, Peck e Vining, 2021).

A Tabela 1 detalha somente as estimativas significativas ($p < 0.05$). A interpretação dos coeficientes mais relevantes revela a magnitude de diferentes fatores, sendo que a categoria de referência para variáveis categóricas é sempre a primeira (ex:




Figura 3: Heatmap do Eta-quadrado (η^2) entre Questões Socioeconômicas e Notas.

para renda, a referência é “Nenhuma renda”; para escolaridade, “Nunca estudou”).

A interpretação dos coeficientes do modelo revela aspectos relevantes das desigualdades educacionais refletidas no desempenho dos estudantes. A variável raça mostrou-se estatisticamente significativa: tomando a autodeclaração branca como referência, estudantes que se identificam como pretos ou pardos obtiveram, em média, notas 17,5 e 10,16 pontos mais baixas, respectivamente. Por outro lado, alunos que se autodeclararam amarelos apresentaram um desempenho 20,9 pontos superior. Mesmo após o controle por fatores como renda e tipo de escola, esses resultados sugerem a presença de desigualdades estruturais que afetam o desempenho no ENEM.

Outro destaque é a faixa etária, que apresentou um efeito negativo expressivo (-29,04 pontos), indicando penalização associada à defasagem idade-série, uma realidade comum entre estudantes que enfrentam trajetórias escolares mais irregulares.

No que diz respeito ao tipo de escola, o fato de o estudante ter cursado o ensino médio em instituição privada esteve associado a um ganho médio de 30,12 pontos na nota final, mesmo após o controle por outras variáveis. Isso evidencia a vantagem educacional proporcionada pelo setor privado no contexto analisado.

Tabela 1: Resumo dos coeficientes selecionados do Modelo de Regressão Final

Variável	Estimativa	Desvio Padrão
(Intercepto)	481.61	64.98
Raça (Preta)	-17.53	8.43
Raça (Parda)	-10.16	3.97
Raça (Amarela)	20.09	6.82
Faixa Etária (Não Ideal)	-29.04	9.35
Escola (Privada)	30.12	3.97
Q006H (Renda R\$5.2k-6.6k)	63.39	28.93
Q006I (Renda R\$6.6k-7.9k)	59.94	29.35
Q006J (Renda R\$7.9k-9.2k)	69.13	29.32
Q006K (Renda R\$9.2k-10.5k)	69.65	29.54
Q006L (Renda R\$10.5k-11.8k)	64.50	29.75
Q006M (Renda R\$11.8k-13.2k)	74.82	30.25
Q006N (Renda R\$13.2k-15.8k)	86.22	29.83
Q006O (Renda R\$15.8k-19.8k)	62.43	29.62
Q006P (Renda R\$19.8-26.4)	90.97	30.03
Q006Q (Renda > R\$26.4k)	99.04	29.79
Q009B (1 Quarto)	-126.45	46.56
Q009C (2 Quartos)	-107.55	45.07
Q009D (3 Quartos)	-114.51	45.21
Q009E (4 ou mais Quartos)	-114.90	45.01
Q013B (1 Freezer)	11.38	3.54
Q016C (2 Micro-Ondas)	-31.48	10.55
Q017B (1 Lava Louça)	17.21	5.12
Q021B (TV por Assinatura)	-14.55	3.32
Q022C (2 Celulares)	26.00	13.02
Q024B (1 Computador)	12.27	4.25
Q024C (2 Computadores)	24.77	5.31
Q024D (3 ou mais Computadores)	27.44	6.29
Q025B (Tem Internet)	32.24	14.27

Entre os fatores socioeconômicos, a renda familiar (Q006) manteve-se como uma das variáveis mais influentes do modelo. Seu impacto foi gradativo, chegando a representar um ganho de até 99,04 pontos na faixa de renda mais alta. Além disso, o acesso à tecnologia revelou-se crucial: possuir 3 ou mais computadores em casa (Q024D) esteve associado a um aumento de 27,44 pontos, enquanto o acesso à internet (Q025B) correspondeu a um incremento de 32,24 pontos na nota média.

O modelo também apontou resultados inesperados que merecem consideração. As variáveis que medem a escolaridade dos pais (Q001 e Q002), por exemplo, não apresentaram significância estatística. Isso pode indicar que seus efeitos foram absorvidos

por preditores mais diretos, como a renda e o tipo de escola. Outro achado contraintuitivo foi a associação negativa entre o número de quartos no domicílio (Q009) e o desempenho acadêmico. Uma hipótese plausível é que essa variável esteja refletindo, indiretamente, a densidade domiciliar, ou seja, residências com muitos quartos podem também abrigar muitos moradores (Q005), o que pode comprometer as condições de estudo em casa.

Por fim, a análise conjunta do modelo de regressão (Tabela 1) e do heatmap (Figura 3) revela de forma coesa o impacto das condições socioeconômicas no desempenho do ENEM. O heatmap destaca que a renda (Q006), o acesso a um computador (Q024) e o capital familiar (implícito em questões como a escolaridade dos pais) são os fatores mais determinantes. O modelo de regressão, por sua vez, quantifica essa relação, confirmando que maiores faixas de renda, estudar em escola privada e possuir acesso à tecnologia elevam a nota final.

3.3 Diagnóstico do Modelo

A análise de resíduos (Figura 4) e o gráfico half-normal com envelopes simulados (Figura 5) indicam um bom ajuste do modelo. No gráfico half-normal, quase 95% dos pontos estão contidos dentro dos envelopes de simulação. Isso sugere que o modelo descreve adequadamente a variabilidade dos dados, sem violações severas de suas premissas (Moral, Hinde e Demétrio, 2017).

4 CONCLUSÃO

Os resultados deste estudo evidenciam que o desempenho dos estudantes de Maringá no ENEM 2023 é explicado por uma combinação complexa de fatores socioeconômicos. Mais do que a renda familiar, aspectos como o tipo de escola frequentada e a cor/raça declarada pelo estudante se mostram componentes centrais das desigualdades observadas. Além disso, o acesso a recursos tecnológicos, como computadores e internet, também mostrou impacto relevante nas notas.

Essas conclusões estão em consonância com achados de pesquisas anteriores que associam o desempenho no ENEM a desigualdades socioeconômicas persistentes (Melo *et al.*, 2021; Oliveira, 2013). Nesse contexto, os resultados reforçam a necessidade de




Figura 4: Gráficos de Diagnóstico do Modelo de Regressão.




Figura 5: Gráfico Half-Normal com Envelope de Simulação.

políticas públicas que ultrapassem ações compensatórias baseadas apenas em renda. É fundamental promover intervenções estruturais voltadas à valorização e qualificação da rede pública de ensino, bem como ao enfrentamento das disparidades raciais e do acesso desigual à infraestrutura educacional.

5 ANEXO

Tabela 2: Dicionário de Variáveis - ENEM 2023

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
TP_SEXO	Sexo	M	Masculino
		F	Feminino
TP_COR_RACA	Cor ou raça	1	Branca
		2	Preta
		3	Parda
		4	Amarela
		5	Indígena
TP_FAIXA_ETARIA	Faixa etária	Ideal	Menor ou igual a 18 anos
		Não ideal	Maior que 18 anos
TP_ESCOLA	Tipo de escola do Ensino	1	Pública
	Médio	2	Privada
Q001	Escolaridade do pai/responsável	A	Nunca estudou.
		B	Não completou o 5º ano
		C	Completou o 5º ano, mas não completou o 9º ano
		D	Completou a 9º ano, mas não completou o Ens. Médio.
		E	Completou o Ens. Médio, mas não completou a Faculdade.
		F	Completou a Faculdade, mas não completou a Pós-graduação.
		G	Completou a Pós-graduação.
Q002	Escolaridade da	A	Nunca estudou.
	mãe/responsável	B	Não completou o 5º ano

Tabela 2 – *Continuação*

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
		C	Completo o 5º ano, mas não completo o 9º ano
		D	Completo a 9º ano, mas não completo o Ens. Médio.
		E	Completo o Ens. Médio, mas não completo a Faculdade.
		F	Completo a Faculdade, mas não completo a Pós-graduação.
		G	Completo a Pós-graduação.
Q003	Ocupação do Pai ou responsável	A	Grupo 1: Trabalhador rural/extração
		B	Grupo 2: Trabalhador de serviços/comércio/suporte
		C	Grupo 3: Trabalhador qualificado/produção
		D	Grupo 4: Profissional técnico/pequeno empresário/supervisor
		E	Grupo 5: Profissional nível superior/grande empresário/alta gestão
Q004	Ocupação da Mãe ou responsável	A	Grupo 1: Trabalhador rural/extração
		B	Grupo 2: Trabalhador de serviços/comércio/suporte
		C	Grupo 3: Trabalhador qualificado/produção
		D	Grupo 4: Profissional técnico/pequeno empresário/supervisor
		E	Grupo 5: Profissional nível superior/grande empresário/alta gestão
Q005	Quantas pessoas moram na residência?	1-20	De 1 a 20 pessoas
Q006	Renda mensal da família	A	Nenhuma renda.
		B	Até R\$1320

Tabela 2 – *Continuação*

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
		C	De R\$1320 a R\$1980
		D	De R\$1980 a R\$2640
		E	De R\$2640 a R\$3300
		F	De R\$3300 a R\$3960
		G	De R\$3960 a R\$5280
		H	De R\$5280 a R\$6600
		I	De R\$6600 a R\$7920
		J	De R\$7920 a R\$9240
		K	De R\$9240 a R\$10560
		L	De R\$10560 a R\$11880
		M	De R\$11880 a R\$13200
		N	De R\$13200 a R\$15840
		O	De R\$15840 a R\$19800
		P	De R\$19800 a R\$26400
		Q	Acima de R\$26400
Q007	Tem empregado(a) doméstico(a)?	A	Não.
		B	Sim, um ou dois dias por semana
		C	Sim, três ou quatro dias por semana
		D	Sim, pelo menos cinco dias por semana
Q008	Tem banheiro?	A	Não
		B	Sim, um

Tabela 2 – *Continuação*

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
		C	Sim, dois
		D	Sim, três.
		E	Sim, quatro ou mais
Q009	Tem quartos para dormir?	A	Não.
		B	Sim, um
		C	Sim, dois
		D	Sim, três
		E	Sim, quatro ou mais
Q010	Tem carro?	A	Não.
		B	Sim, um.
		C	Sim, dois.
		D	Sim, três ou mais.
Q011	Tem motocicleta?	A	Não.
		B	Sim, uma.
		C	Sim, duas.
		D	Sim, três ou mais.
Q012	Tem geladeira?	A	Não.
		B	Sim, uma.
		C	Sim, duas.
		D	Sim, três ou mais.

Tabela 2 – *Continuação*

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
Q013	Tem freezer?	A	Não.
		B	Sim, um.
		C	Sim, dois.
		D	Sim, três ou mais.
Q014	Tem máquina de lavar roupa?	A	Não.
		B	Sim, uma.
		C	Sim, duas ou mais.
Q015	Tem máquina de secar roupa?	A	Não.
		B	Sim, uma.
		C	Sim, duas ou mais.
Q016	Tem forno micro-ondas?	A	Não.
		B	Sim, um.
		C	Sim, dois ou mais.
Q017	Tem máquina de lavar louça?	A	Não.
		B	Sim, uma
		C	Sim, duas ou mais
Q018	Tem aspirador de pó?	A	Não
		B	Sim
Q019	Tem televisão em cores?	A	Não
		B	Sim, uma

Tabela 2 – *Continuação*

Nome da Variável	Descrição da Variável	Categoria	Descrição da Categoria
		C	Sim, duas
		D	Sim, três ou mais
Q020	Tem aparelho de DVD?	A	Não
		B	Sim
Q021	Tem TV por assinatura?	A	Não
		B	Sim
Q022	Tem telefone celular?	A	Não.
		B	Sim, uma
		C	Sim, duas
		D	Sim, três ou mais
		E	Sim, quatro ou mais
Q023	Tem telefone fixo?	A	Não
		B	Sim
Q024	Tem computador?	A	Não.
		B	Sim, um.
		C	Sim, dois.
		D	Sim, três ou mais.
Q025	Tem acesso à Internet?	A	Não.
		B	Sim.

REFERÊNCIAS

- AKAIKE, H. [A new look at the statistical model identification](#). **IEEE Transactions on Automatic Control**, v. 19, n. 6, p. 716–723, 1974.
- BAKEMAN, R. [Recommended effect size statistics for repeated measures designs](#). **Behavior Research Methods**, v. 37, n. 3, p. 379–384, ago. 2005.
- BURNHAM, K. P.; ANDERSON, D. R. **Model selection and multimodel inference: A practical information-theoretic approach**. 2nd. ed. New York: Springer-Verlag, 2002.
- CRAMÉR, H. **Mathematical Methods of Statistics**. Princeton, NJ: Princeton University Press, 1946.
- INEP. [Entenda a sua nota no Enem: Guia do participante](#). Brasília, DF: Ministério da Educação, 2021.
- LIMA, C. C. V. DE; BRIGHENTI, C. R. G. [Desempenho de estudantes de Minas Gerais no Exame Nacional do Ensino Médio considerando variáveis socioeconômicas](#). **Educação e Pesquisa**, v. 49, p. e253303, 2023.
- MELO, R. O. *et al.* [Impacto das variáveis socioeconômicas no desempenho do Enem: uma análise espacial e sociológica](#). **Revista de Administração Pública**, v. 55, n. 6, p. 1271–1294, nov. 2021.
- MONTGOMERY, D. C.; PECK, E. A.; VINING, G. G. **Introduction to Linear Regression Analysis**. 6th. ed. Hoboken, NJ: John Wiley & Sons, 2021.
- MORAL, R. A.; HINDE, J.; DEMÉTRIO, C. G. B. [Half-Normal Plots and Overdispersed Models in R: The hnp Package](#). **Journal of Statistical Software**, v. 81, n. 10, p. 1–23, 2017.
- OLIVEIRA, R. T. T. DE. [ENEM: limites e possibilidades do Exame Nacional do Ensino Médio enquanto indicador de qualidade escolar](#). São Paulo, Brazil: Faculdade de Educação, Universidade de São Paulo, 2013.
- OZILI, P. K. [The Acceptable R-Square in Empirical Modelling for Social Science Research](#). **SSRN Electronic Journal**, jun. 2022.
- R CORE TEAM. [R: A Language and Environment for Statistical Computing](#). Vienna, Austria: R Foundation for Statistical Computing, 2025.
- SOARES, J. F.; COLLARES, A. C. M. [Recursos familiares e o desempenho cognitivo dos](#)

alunos do ensino básico. **Dados**, v. 49, n. 3, p. 615–650, 2006.