

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Modelos Lineares Generalizados

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

1 INTRODUÇÃO

A doença cardíaca representa um dos grandes desafios da saúde pública em diversos países, afetando milhões de pessoas e gerando impactos econômicos e sociais. O diagnóstico precoce é fundamental para melhorar a qualidade de vida e reduzir a mortalidade ligadas a essa condição.

Nesse trabalho, analisamos um conjunto de dados clínicos de pacientes com um modelo linear generalizado (GLM). Considerando que o interesse dessa pesquisa tem uma resposta binária (presença ou não de doença cardíaca), utilizamos a distribuição binomial com função de ligação logito. O objetivo é identificar as características de risco mais associadas com a presença da doença. Contribuindo para um entendimento mais aprofundado dessa condição. O banco de dados analisado é composto por 303 observações de pacientes, incluindo indivíduos com e sem a doença. As informações estão organizadas em 5 variáveis numéricas e 9 categóricas, detalhadas na tabela 1.

Tabela 1: Descrição das variáveis

Quantitativas		Qualitativas	
age	Idade do paciente (anos)	sex	Sexo ("Female", "Male")
rest.bp	Pressão arterial (mmHg)	chest.pain	Tipo de dor no peito
chol	Colesterol (mg/dl)	sugar	Glicemia em jejum ("High", "Normal")
max.rate	Frequência cardíaca máx	ecg	ECG em repouso
st.ex_vs_rest	Diferença ST (mm)	ang.ex	Angina induzida por exercício
		st.slope	Inclinação do segmento ST
		fluoroscopy	Nº de vasos na fluoroscopia
		thalassemia	Tipo de talassemia
		hd	Diagnóstico cardíaco

2 METODOLOGIA

Para compreender a natureza dos dados e sua distribuição, realizamos uma análise descritiva usando os gráficos e métricas apropriada para cada tipo de variável. Em seguida, escolhemos um modelo inicial com distribuição binomial e função de ligação canônica logito. Também criamos variações desse modelo, buscando por diferentes funções de ligação e comparamos seus desempenhos. Nosso objetivo foi identificar o modelo mais adequado e simples. Todos os modelos foram avaliados quanto aos

pressupostos necessários para serem válidos e foram comparados entre si. Por fim, interpretamos os coeficientes do melhor modelo selecionado, juntamente com o seus respectivos intervalos de confiança, para verificar as associações mais importantes com a presença de doença cardíaca.

3 RESULTADOS

3.1 Análise descritiva

Como está destacado na Figura 1, entre os pacientes com a doença cardíaca, podemos observar um claro predomínio de homens, que representam 82% desse grupo. A maioria desses não apresentam dor no peito (assintomática), sendo cerca de 75% dos casos, o que indica que muitos indivíduos doentes não manifestam sintomas característicos. No exame de eletrocardiograma desta-se a presença de hipertrofia ventricular esquerda 58% dos pacientes, enquanto ST do tipo “Flat” representam 66%. Sugerindo padrões elétricos específicos associados à doença.

Além disso, dois terços apresentam pelo menos um vaso principal obstruído na fluoroscopia, apontando o comprometimento vascular nesse grupo. A talassemia do tipo “Reversible Defect” é o mais observado, 64% dos casos. Esses resultados mostram que a doença está associada ao sexo masculino, à ausência de sintomas comuns, alterações estruturais e múltiplos fatores de riscos clínicos, questões que serão aprofundadas nas análises seguintes.

Ademais, ao analisar o grupo de não doentes, observamos uma distribuição mais equilibrada entre homens e mulheres, maior frequência de dores no peito, menor frequência de hipertrofia ventricular esquerda e de vasos sanguíneos obstruídos. Essas diferenças reforçam que características encontradas em pacientes doentes não ocorrem na mesma proporção entre os não doentes. Sugerindo uma possível relação com a doença cardíaca.

Para as variáveis numéricas, embora o grupo com doença cardíaca apresente médias maiores para idade, pressão arterial, colesterol e diferença de ST e valores inferiores para frequência cardíaca máxima, essas diferenças entre grupos são pequenas. Sugerindo que, de forma isolada, essas variáveis não descrevem os grupos clínicos e a análise deve ser




Figura 1: Proporção de cada variável em relação ao diagnóstico

feita em conjunto dos fatores e não apenas observar as estatísticas básicas das variáveis quantitativas, pois elas não parecem até então separar bem os grupos conforme a tabela 2.

Tabela 2: Estatísticas descritivas das variáveis quantitativas – Não doentes

Variável	Média	DP	Mín	Q1	Med	Q3	Máx
age	52,6	9,5	29	44,8	52	59	76
rest.bp	129	16,2	94	120	130	140	180
chol	243	53,5	126	209	234	267	564
max.rate	158	19,2	96	149	161	172	202
st.ex_vs_rest	0,59	0,78	0	0	0,2	1,02	4,2

Tabela 3: Estatísticas descritivas das variáveis quantitativas – Doentes

Variável	Média	DP	Mín	Q1	Med	Q3	Máx
age	54,4	9,0	29	48	56	61	77
rest.bp	132	17,6	94	120	130	140	200
chol	247	51,8	126	211	241	275	564
max.rate	150	22,9	71	134	153	166	202
st.ex_vs_rest	1,04	1,16	0	0	0,8	1,6	6,2

3.2 Comparação e Seleção de Modelos

Para garantir a escolha do modelo mais adequado, que equilibra poder de ajuste e parcimônia, foram realizadas comparações formais entre diferentes modelos. Foram

empregados dois critérios principais: o Teste da Razão de Verossimilhanças (LRT) para modelos aninhados e o Critério de Informação de Akaike (AIC) para uma comparação mais ampla.

3.2.1 Análise via Teste da Razão de Verossimilhanças (LRT)

O LRT foi utilizado para comparar três modelos aninhados:

- Modelo 0: Modelo nulo, contendo apenas o intercept;.
- Modelo 1: Um modelo complexo incluindo todos os preditores;
- Modelo 2: Um modelo mais simples, sendo um subconjunto do modelo 1, obtido via seleção *stepwise*.

Tabela 4: Comparação de modelos via LRT

Modelo	GL Res.	Deviance Res.	Dif. GL	Dif. Deviance	Valor p
Modelo 0	302	417.98			
Modelo 1	283	194.09	19	223.89	$< 2e-16$
Modelo 2	290	200.86	-7	-6.77	0.4533

A tabela de análise de deviance (Tabela 1) mostrou que a passagem do modelo 0 para o modelo 1 resulta em uma redução da deviance (223.89), com um valor p extremamente baixo ($< 2e-16$), indicando que o modelo completo é superior ao modelo nulo.

O ponto crucial da análise, no entanto, é a comparação entre o modelo completo e o simplificado. O teste avalia se a remoção das variáveis que diferenciam os dois modelos resulta em uma perda significativa de ajuste. O resultado do LRT para esta comparação foi um valor de p de 0.4533.

Como o valor de p (0.4533) é muito superior ao nível de significância usual (ex: $\alpha = 0.05$), não há evidências estatísticas para afirmar que o modelo mais complexo é melhor que o modelo mais simples. Em outras palavras, as variáveis adicionais não trazem uma melhoria significativa ao ajuste do modelo que justifique sua inclusão. Pelo princípio da parcimônia, o LRT favorece a escolha do modelo 2.

3.2.2 Análise via Critério de Informação de Akaike (AIC)

O AIC é uma medida que avalia a qualidade do ajuste de um modelo enquanto penaliza sua complexidade. Valores de AIC mais baixos indicam um melhor modelo. Foram comparados os valores de AIC do mesmo modelo anterior obtido via seleção *stepwise*, porém com as funções de ligação *probit* e *cloglog*.

Tabela 5: Comparação dos valores de AIC para os modelos

Modelo	df	AIC
logit	13	226.86
probit	13	228.90
cloglog	13	232.52

Conforme a tabela 2, o modelo com função de ligação *logit* apresentou o menor valor de AIC (226.86) entre os modelos avaliados. Isso reforça que ele oferece o melhor equilíbrio entre a fidelidade aos dados (bom ajuste) e a simplicidade (menor número de parâmetros).

3.3 Modelo Final

3.3.1 Equação

A equação do modelo de regressão logística estabelece a relação entre as variáveis preditoras e a probabilidade de um indivíduo ter doença cardíaca ($P(\text{hd} = 1)$). O preditor linear, denotado por η_i (eta), é modelado da seguinte forma, utilizando a definição explícita da função de ligação logit:

$$\begin{aligned} \eta_i = \log \left(\frac{P(\text{hd} = 1)}{1 - P(\text{hd} = 1)} \right) = & -4.33 + 1.37x_{\text{sexMale}} - 1.11x_{\text{chest.painAtypical}} \\ & - 2.07x_{\text{chest.painNon-anginal}} - 2.31x_{\text{chest.painTypical}} \\ & + 0.02x_{\text{rest.bp}} + 0.84x_{\text{ang.exSim}} + 0.41x_{\text{st.ex_vs_rest}} \\ & - 0.82x_{\text{st.slopeDown}} - 1.36x_{\text{st.slopeUp}} + 1.29x_{\text{fluoroscopy}} \\ & - 0.12x_{\text{thalassemiaFixed}} + 1.33x_{\text{thalassemiaReversible}} \end{aligned}$$

Nesta equação:

- $\log\left(\frac{P}{1-P}\right)$ representa o logaritmo natural da razão de chances (logit) de ter a doença.
- η_i é o preditor linear para a i -ésima observação (ou seja, para um paciente específico).

3.3.2 Resíduos

A validação do modelo é uma etapa essencial na modelagem estatística. Para isso, foram utilizados gráficos de diagnóstico (Figura 1) com o objetivo de avaliar os resíduos e a influência das observações.

- Resíduos: Os gráficos de resíduos versus valores ajustados e o gráfico *scale-location* exibem um padrão em "V", característico dos resíduos de Pearson em regressões logísticas. Não há indícios de não linearidade ou heterocedasticidade preocupante dentro desse padrão.
- Normalidade e outliers: A distribuição dos resíduos foi avaliada por meio de um gráfico Q-Q e de um envelope simulado. Apenas 3 observações (0,99%) ficaram fora do envelope de 95%, o que sugere boa aderência à distribuição teórica e ausência de outliers relevantes.
- Pontos de alavanca: Os gráficos de alavancagem e Distância de Cook mostram que nenhuma observação exerce influência excessiva sobre os coeficientes do modelo. As distâncias de Cook permaneceram baixas, reforçando a qualidade do ajuste.

3.3.3 Coeficientes

A interpretação foi realizada através da razão de chances (Odds Ratio - OR), obtida pela exponenciação dos coeficientes. A OR quantifica o impacto de cada variável na chance de um paciente ter doença cardíaca em relação à categoria de referência. A tabela abaixo resume as ORs para as variáveis estatisticamente significantes.

A análise das razões de chances (OR), apresentadas na Tabela 6, revela o impacto e a direção da associação de cada preditor com a doença cardíaca. Os fatores de risco mais proeminentes são o sexo masculino (OR = 3.94), a talassemia com defeito reversível (OR = 3.79) e a fluoroscopia (OR = 3.62). Estes resultados indicam que a chance de um homem ter a doença é aproximadamente quatro vezes a de uma mulher; a de um paciente




Figura 2: Análise de resíduos

Tabela 6: Razão de chances (OR) e intervalos de confiança (IC) de 95%

Variável	OR	IC (95%)
Sexo (Masculino vs. Feminino)	3.9409	[1.5649, 10.5981]
Dor Torácica (Angina Atípica vs Assintomático)	0.3288	[0.1082, 0.9255]
Dor Torácica (Não Anginosa vs Assintomático)	0.1265	[0.0475, 0.3140]
Dor Torácica (Angina Típica vs Assintomático)	0.0996	[0.0257, 0.3428]
Pressão Art. em Repouso (mmHg)	1.0220	[1.0019, 1.0437]
Angina Induzida por Exercício (Sim vs Não)	2.3059	[1.0026, 5.2795]
Depressão ST Exercício	1.5140	[0.9928, 2.3739]
Inclinação do Segmento ST (Descendente Vs. Reta)	0.4400	[0.0867, 2.0245]
Inclinação do Segmento ST (Ascendente Vs. Reta)	0.2560	[0.1059, 0.5951]
Nº de Vasos Principais Corados (Fluoroscopia)	3.6212	[2.2511, 6.1658]
Talassemia (Defeito Fixo Vs. Normal)	0.8879	[0.2044, 3.9514]
Talassemia (Defeito Reversível Vs. Normal)	3.7935	[1.7242, 8.5377]

com defeito reversível de talassemia é 3.8 vezes a de um indivíduo com resultado normal; e para cada vaso adicional colorido por fluoroscopia, a chance da doença aumenta em 262%. Essa combinação entre os efeitos da fluoroscopia e do sexo é mostrada na Figura 3.

Outros fatores que elevam o risco, ainda que com menor magnitude, são a angina induzida por exercício, que aumenta a chance em 131% (OR = 2.31), e a pressão arterial em repouso, onde cada 1 mmHg de aumento eleva a chance em 2% (OR = 1.02).

Além disso, o modelo também identificou fatores com efeito protetor. Pacientes que reportam dor torácica do tipo não anginosa apresentam uma chance 87% menor de ter a doença em comparação com pacientes assintomáticos (OR = 0.13). De forma similar, uma inclinação ascendente do segmento ST no eletrocardiograma está associada a uma redução de 74% na chance da doença quando comparada a uma inclinação plana (OR = 0.26). Essa combinação é mostrada na Figura 4.

4 CONCLUSÃO

Este estudo se propôs a identificar os principais fatores de risco associados à presença de doença cardíaca em uma amostra de 303 pacientes, utilizando um modelo linear generalizado. Por meio de um processo de seleção que envolveu o Teste da Razão de Verossimilhanças e o Critério de Informação de Akaike (AIC), um modelo de regressão




Figura 3: Probabilidade de doença de acordo com as variáveis fluoroscopia e sexo




Figura 4: Probabilidade de doença de acordo com as variáveis tipo de dor torácica e inclinação do segmento ST

logística foi escolhido. A validação por análise de resíduos confirmou a adequação do modelo final, garantindo a confiabilidade dos resultados.

Os resultados quantificados pela razão de chances (OR) indicam um perfil de risco multifatorial. Os fatores mais impactantes que aumentam a chance de um paciente ter a doença são sexo masculino, talassemia com defeito reversível e número de vasos na fluoroscopia.

Além desses, o modelo também destacou fatores protetores significativos. Pacientes com dor torácica não anginosa e com inclinação ascendente do segmento ST mostraram-se menos propensos a ter a doença em comparação com as categorias de referência.

Em suma, o trabalho demonstra que a presença de doença cardíaca está fortemente ligada a uma combinação de fatores demográficos, achados clínicos e resultados de exames específicos. O modelo logístico desenvolvido não apenas confirma a relevância desses preditores, mas também quantifica seu impacto, ajudando na compreensão da doença e na identificação de perfis de alto risco.