

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Seminário de Séries Temporais

Felipe Yamamoto Tenedine (RA 131790)

David Eduardo Milbauer (RA 123522)

Maringá - PR

1 Estatística descritiva

1.1 Cavalinha

Existe uma tendência alta com inclinação linear positiva, um aumento de 139329 unidades por período. O modelo linear se ajusta bem aos dados com coeficiente de determinação aproximado de 0.85. As médias anuais crescem consideravelmente, sendo 450 mil em 2020, 513 mil em 2021, 580 mil em 2022, 865 mil em 2023 e finalmente 993 mil em 2024. O resíduo do modelo linear da tendência seguem os pressupostos apropriados.

Pelo gráfico da decomposição, percebemos que há um padrão anual de sazonalidade. Havendo sempre um pico no começo e no fim dos anos e um vale nos meses centrais.







Tabela 1: Média de toneladas por ano

Ano	Toneladas
2020	449770.3
2021	512879.3
2022	584379.0
2023	864901.5
2024	993455.8

1.2 Temperatura


A temperatura é periódica anualmente, com picos sempre no começo do ano. Não há uma tendência visível na série, ela parece se estabilizar em de um intervalo de 10°C a 20°C , mas pelos gráficos de acf e pacf indicam autocorrelações significativas o que evidência não estacionaridade.

O modelo linear para a sazonalidade tem um coeficiente de determinação alto (0.9602) se ajustando muito bem. Nele percebemos que os meses de Janeiro, Fevereiro e Dezembro são os picos 17.7, 17.65 e 17.43 respectivamente. Enquanto os meses de vale são Maio, Julho e Junho e Agosto com coeficientes 10.52, 8.92, 7.66, e 7.89 respectivamente. Os demais meses representam transições suaves entre picos e vales, com decaimento ou crescimento gradual.



1.2.1 Cavalinha e temperatura

Como um dos interesses é analisar a relação entre quantidade pescada de cavalinha e a temperatura, podemos observar os gráficos de sazonalidade, com isso nota-se, inicialmente, que há alguma relação entre as séries. Embora não seja uma relação perfeita, mas os picos e vales tendem a ocorrer em momentos conjuntos, indicando um padrão sazonal compartilhado. Conforme podemos observar no gráfico a seguir.



1.2.2 Modelos iniciais

Foram considerados cinco modelos iniciais para analisar a quantidade de pescado. São eles $ARIMA(0,1,1)(1,0,0)$ [12], encontrado a partir da função `auto.arima` do R. $ETS(A,A,A)$, $NNAR(2,1,2)$ [12], e por fim, dois modelos semelhantes aos primeiros, mas com regressor na temperatura. Seriam os $ARIMA(0,1,1)(1,0,0)$ e $NNAR(2,1,2)$ [12].

O primeiro modelo Sarima tem uma componente $MA(1)$ e uma diferenciação para transformar a série em estacionária. Na parte sazonal, há apenas a componente $AR(1)$ sem diferenciação com período de 12 meses, ou seja, anualmente. Há uma transformação leve de Box-Cox com $\lambda = 0.9037472$. Os coeficientes estimados para o modelo foram, `ma1`

= -0.7595 (desvio de 0.0863), indicando uma correlação negativa entre o termo atual e o erro anterior. $\text{sar1} = 0.3950$ (desvio de 0.1084), Indicando uma correlação positiva entre o valor do período atual com o anterior, o drift 2638.415 (desvio de 1112.052) mostra tendência positiva de crescimento na série. O teste de Ljung-Box, com p-valor igual 0.5998 mostra que os resíduos estão adequados para o modelo. Sem autocorrelação e independentes.

O modelo de Suavização Exponencial da série cavalinha com todas as componentes de erro, tendência e sazonalidade aditivas. Nos parâmetros de suavização $\alpha = 0.2612$, $\beta = 1 \times 10^{-4}$ e $\gamma = 1 \times 10^{-4}$ os valores estimados pelo modelo são pequenos, então nos mostra que as componentes mudam de forma mas lenta e se baseiam numa média mais longa de observações passadas. Valores próximos de 1, indicam que se ajustam mais rapidamente nos dados. A transformação de Box-Cox nesse modelo foi baixa $\lambda = 0.9037$. O teste de Ljung-Box também apontou adequação dos resíduos nesse modelo. Em relação ao AIC, o modelo Sarima anterior teve um ajuste menor do que o ETS, sendo uma diferença aproximada de 121.431.

O modelo de redes neurais NNAR utiliza 2 lags não sazonais e 2 lags sazonais com período de 12 meses. O teste também indica que os pressupostos para os resíduos foram atendidos. Como é um modelo não linear não temos a informação de AIC para comparar com os demais apresentados até então.

Ainda assim ajustamos um NNAR com regressor na temperatura, podemos avaliar os dois comparando suas variâncias dos erros. O modelo que adiciona a temperatura apresentou um erro $\sigma^2 = 5.163 \times 10^9$ contra $\sigma^2 = 5.924 \times 10^9$ do modelo sem ela. Isso é uma redução de aproximadamente 14%. Indicando que o segundo modelo se ajusta melhor aos dados. E que, como havíamos observado nos gráficos iniciais, a temperatura pode ter influência na quantidade de kg pescado.

Por fim, o modelo Sarima com regressor na temperatura, com componente MA(1) e uma diferenciação. Na parte sazonal, um componente AR(1) sem diferenciação com 12 períodos. A inclusão da temperatura não melhorou o modelo, visto que seu AIC e erro da variância estimado comparado com o primeiro Sarima ajustado são maiores. Como nos modelos não lineares (NNAR) houve diferença, há evidências de que essa relação entre quantidade de kg pescado e temperatura possa ser não linear e o modelo de redes neurais

tenha sido capaz de entender esse comportamento.

Tabela 2: Resumo do Desempenho dos Modelos de Séries Temporais

Modelo	Variância do Erro (σ^2)	AIC	Conclusão Ljung-Box
ARIMA (0,1,1)(1,0,0)[12]	6.429×10^8	1626.16	RB
ETS(A,A,A)	5.513×10^8	1747.59	RB
NNAR(2,1,2)[12]	5.924×10^9	N/A	RB
ARIMAX $c/ temp$	6.456×10^8	1626.80	RB
NNARX $c/ temp$	5.163×10^9	N/A	RB

2 Validação Cruzada

Para garantir a qualidade das previsões, foi usada uma validação cruzada com origem deslizante inicial de 48 meses, incrementada mensalmente. Para os modelos que utilizam a temperatura como preditor, não foram utilizados dados futuros reais da temperatura. Em vez disso, a temperatura foi projetada simultaneamente, incorporando a incerteza no erro final.

3 Resultados

3.1 Desempenho dos Modelos

Foram testados cinco modelos distintos. A Tabela 3 apresenta o ranking de acurácia baseado na Raiz do Erro Quadrático Médio (RMSE) obtido na validação cruzada e a imagem apresenta o boxplot dos erros para cada modelo.

Tabela 3: Comparativo de Erros na Validação Cruzada

Modelo	RMSE	MAE
ARIMA c/ Regressão	99.381,7	83.297,0
ARIMA Univariado	101.657,5	87.507,8
ETS Univariado	102.493,3	78.445,6
NNETAR Univariado	107.298,8	89.842,6
NNETAR c/ Regressão	107.911,0	87.804,3




Figura 1: Distribuição dos Erros de Previsão (Validação Cruzada)
Comparativo de acurácia entre modelos

O modelo de regressão com erros ARIMA apresentou o melhor desempenho considerando RMSE, porém, o modelo ETS apresentou menor Erro Absoluto Médio (MAE). A inclusão da temperatura melhorou a assertividade do modelo.

3.2 Especificação do Modelo Final

O modelo ARIMA com a temperatura como variável regressora foi reajustado com a base completa de dados:

Regressão com erros $\text{ARIMA}(0, 1, 1)(1, 0, 0)_{12}$

Destaca-se o coeficiente positivo da variável temperatura, indicando que aumentos na temperatura tendem a estar associados a aumentos na captura da espécie no período analisado.

Como comparação, manteve-se o modelo $\text{ETS}(A,A,A)$ (Erro, Tendência e Sazonalidade Aditivos).

3.3 Projeção de Faturamento

Considerando um preço de \$8,00/kg, projetou-se a receita para o próximo semestre. As previsões incorporam a incerteza estatística (Intervalos de Confiança de 95%).

Tabela 4: Receita Esperada Acumulada (6 Meses)

Modelo	Receita Esperada	Lim. Inferior (95%)	Lim. Superior (95%)
ARIMA Xreg	56,7 Bilhões	47,0 Bilhões	66,5 Bilhões
ETS (A,A,A)	58,1 Bilhões	49,0 Bilhões	67,4 Bilhões




Figura 2: Previsão Comparativa: Cavalinha (6 Meses)
Comparando o modelo com Temperatura (ARIMA) vs Histórico puro (ETS)

O modelo ETS apresenta-se mais otimista, com uma projeção de receita cerca de 2,5% superior ao modelo ARIMA. Essa divergência ocorre principalmente devido à forma como o ETS projeta os picos sazonais (meses 4 e 6) de forma mais acentuada.

3.4 Limitações e Suposições

É fundamental considerar:

1. **Mudança Climática:** O desempenho do modelo ARIMA está ligado à precisão da previsão da temperatura. Anomalias climáticas não previstas podem prejudicar as projeções.
2. **Preço Estático:** A análise financeira assume preço constante. Não foi considerado a possível variação de preços.
3. **Fatores Omitidos:** Variáveis como custo de pesca ou custo de combustível não foram incluídas no modelo, sendo assumidas constantes ou capturadas de modo indireto.

3.5 Conclusão

Conclui-se que o cenário base para o planejamento deve utilizar o modelo ARIMA com Temperatura como variável regressora, dado seu melhor resultado nos testes de validação cruzada. Espera-se um faturamento próximo a \$56,7 bilhões, com um valor pessimista de 47 bilhões.