

Universidade Estadual de Maringá - UEM

Centro de Ciências Exatas

Departamento de Estatística - DES

Relatório: Correlação e Análise de Componentes Principais
(PCA)

Estatística Multivariada

Felipe Yamamoto Tenedine (RA 131790)

Maringá - PR

1 INTRODUÇÃO

O objetivo deste trabalho é fazer uma análise multivariada de uma base de dados, usando técnicas como análise de correlação e análise de componentes principais (PCA). Para isso, a base de dados escolhida foi a *Heart Disease* do *UC Irvine Machine Learning Repository*. Essa base de dados é composta de 14 variáveis e 303 observações, sendo que cada observação é um paciente. As variáveis são:

- age: idade;
- sex: sexo;
- chest.pain: tipo de dor peito, podendo ser assintomático, angina típica, angina atípica e sem dor anginal;
- rest.bp: pressão sanguínea em repouso;
- chol: colesterol;
- sugar: glicemia em jejum;
- ecg: resultado do eletrocardiograma, podendo ser normal, anormalidade no segmento ST ou com hipertrofia no ventrículo esquerdo;
- max.rate: frequência cardíaca máxima;
- ang.ex: angina induzida por exercício;
- st.ex_vs_rest: depressão do segmento ST induzida por exercício em comparação com o repouso;
- st.slope: inclinação do segmento ST durante exercício, podendo ser para cima, horizontal ou para baixo;
- fluoroscopy: número de vasos grandes coloridos durante fluoroscopia;
- thalassemia: doença sanguínea que afeta o fluxo sanguíneo, podendo assumir os valores normal, defeito fixo(em alguma parte), defeito reversível;
- hd: doença cardíaca.

2 METODOLOGIA

Como ambas as técnicas são para variáveis numéricas, foram excluídas as variáveis nominais para essa análise. Primeiro foi feito um estudo de correlação e, em seguida,

uma análise dos componentes principais. Para a PCA, antes de realizar a análise foi feita a normalização dos dados.

3 RESULTADOS

3.1 Correlação

O gráfico de correlação (figura 1) mostra que não há uma correlação linear forte entre as variáveis. A ausência de correlações muito altas sugere que as variáveis capturam aspectos distintos do fenômeno estudado.

As correlações moderadas (ex.: age com fluoroscopy, st.ex_vs_rest com fluoroscopy) indicam que algumas variáveis podem compartilhar informações, o que pode ser capturado pelos componentes principais no PCA




Figura 1: Gráfico de correlação entre as variáveis numéricas

3.2 PCA

Analisando os resultados da PCA (tabela 1), podemos ver que o primeiro componente explica cerca de 34% da variância dos dados, o segundo 18%, o terceiro 14% e o quarto 12,7%. Na variância acumulada, os 4 primeiros componentes explicam quase 81% da variância.

Tabela 1: Variância explicada por cada componente principal

	eigenvalue	variance.percent	cumulative.variance.percent
Dim.1	2.0802	34.670	34.67
Dim.2	1.0977	18.296	52.97
Dim.3	0.8984	14.973	67.94
Dim.4	0.7668	12.781	80.72
Dim.5	0.7104	11.839	92.56
Dim.6	0.4465	7.442	100.00

Também podemos analisar o quanto cada variável está correlacionada com cada componente (tabela 2). Vemos que as variáveis *age*, *st.ex_vs_rest* e *fluoroscopy* possuem uma correlação alta e negativa com primeiro componente, enquanto que *max.rate* tem uma correlação alta e positiva. Esse primeiro componente parece estar relacionado com a saúde dos vasos e do coração em relação à idade. Já em relação ao segundo componente, *rest.bp* e *chol* têm uma correlação moderada a alta e negativa. Esse componente parece estar relacionado à saúde metabólica. No terceiro componente apenas a correlação alta e positiva de *rest.bp* chama a atenção.

Tabela 2: Correlação de cada variável com os componentes principais

Var	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6
age	-0.7491	-0.1560	-0.0869	-0.4737	0.0479	0.4246
rest.bp	-0.4294	-0.5141	0.7019	-0.0715	0.0732	-0.2196
chol	-0.3010	-0.7126	-0.4900	0.2533	-0.3002	-0.0844
max.rate	0.6513	-0.4505	0.0966	0.2799	0.4102	0.3419
st.ex_vs_rest	-0.6202	0.2899	0.2607	0.6023	-0.2062	0.2408

Var	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6
fluoroscopy	-0.6597	0.1195	-0.2843	0.1789	0.6339	-0.1896

Além disso, é possível plotar a correlação entre cada variável e os 2 primeiros componente e também cada observação em relação aos componentes 1 e 2 para analisar o comportamento dos dados em uma dimensão menor. Por exemplo, na figura 1A não é possível distinguir grupos diferentes. Ao colorir de acordo com a variável *hd* (doença cardíaca), vemos que a distinção é maior pelo componente 1 (pacientes com doença cardíaca estão mais distribuídos no lado negativo do primeiro componente).




Figura 2: Gráfico de dispersão dos 2 primeiros componentes principais

Na figura 3, temos uma representação mais visual dos 2 primeiros componentes da tabela 2. Vemos que o componente 2 explica melhor as correlações entre *rest.bp* e *chol*, enquanto que o componente 1 explica melhor a correlação das demais. Além disso, todas as variáveis, exceto *max.rate* são negativamente correlacionadas com o componente 1. Isso significa que um aumento de qualquer uma, principalmente *fluoroscopy* e *st.ex_vs_rest* vai influenciar negativamente em *max.rate*.




Figura 3: Contribuição de cada variável para os 2 primeiros componentes

4 CONCLUSÃO

A correlação entre as variáveis é uma ótima ferramenta para tirar algumas conclusões sobre os dados. Porém, com o uso de técnicas de estatística multivariada, como a PCA, podemos levar em conta todas as variáveis numéricas, enriquecendo a profundidade da análise.